Taller 1: TAM - 2026-1

1. $x \in \mathbb{R}^2$, con etiquetas $y \in \{-1, +1\}$

Predicción: $\hat{y} = \begin{cases} 1, & w^T x + b > 0 \\ -1, & w^T x + b \leq 0 \end{cases}$; $w \in \mathbb{R}^2$, $b \in \mathbb{R}$

1.1 Frontera de decisión.

$w = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$, $b = -3$, frontera de decisión $w^T x + b = 0$

$$\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x^{(1)} \\ x^{(2)} \end{bmatrix} - 3 = 0 \rightleftarrows x^{(1)} + 2x^{(2)} - 3 = 0$$

$$x^{(2)} = -\frac{1}{2} x^{(1)} + \frac{3}{2} \quad \therefore \quad y = mx + c \rightleftarrows \overbrace{m = -\frac{1}{2}}^{\text{Pendiente}} ; \overbrace{c = \frac{3}{2}}^{\text{Intersección}}$$

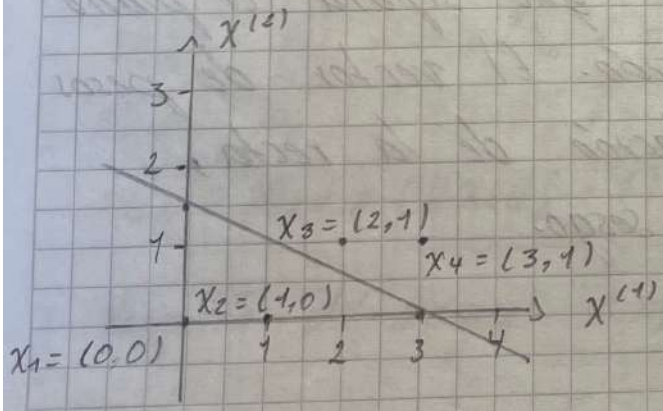
Corte Eje Vertical: $x^{(1)} = 0$

$$0 + 2x^{(2)} - 3 = 0 \rightleftarrows 2x^{(2)} = 3 \rightleftarrows x^{(2)} = \frac{3}{2} = 1.5$$

$A = (0, 1.5)$

Corte Eje Horizontal: $x^{(2)} = 0$

$$x^{(1)} + 2(0) - 3 = 0 \rightleftarrows x^{(1)} = 3 \; ; \; B = (3, 0)$$



$x^{(2)} > -\frac{1}{2} x^{(1)} + \frac{3}{2} \rightarrow$ Puntos situados estrictamente por encima de la recta. (+1)

$x^{(2)} \leq -\frac{1}{2} x^{(1)} + \frac{3}{2} \rightarrow$ Puntos situados por debajo debajo o sobre ella. (-1)

Primera Observación: $x_1 = (0,0) \rightarrow f(x_1) = 1(0) + 2(0) - 3 = -3$

$f(x_1) = -3 \rightarrow -3 \leq 0 \rightarrow$ Cumple que: $\hat{y}_1 = -1$

Pertenece a la clase -1 porque geometricamente el punto

Se encuentra por debajo de la frontera de decisión.

2da Observación: $x_2 = (1, 0) \rightarrow f(x_2) = 1(1) + 2(0) - 3 = -2$

$f(x_2) = -2 \rightarrow -2 \leq 0 \rightarrow \hat{y}_2 = -1$

3cera Observación: $x_3 (2, 1) \rightarrow f(x_3) = 1(2) + (2)(1) - 3$

$f(x_3) = 1 \rightarrow 1 > 0 \rightarrow \hat{y}_1 = 1$

Pertenece a la clase +1 porque geometricamente se encuentra por encima de la frontera. Entonces la función de decisión genera un valor estrictamente positivo.

4ta Observación: $x_4 = (3, 1) \rightarrow f(x_4) = 1(3) + 2(1) - 3 = 2$

$f(x_4) = 2 \rightarrow 2 > 0 \rightarrow \hat{y}_4 = +1$

Vector de Predicción: $\hat{y} = \begin{bmatrix} -1 \\ -1 \\ +1 \\ +1 \end{bmatrix}$

La frontera de decisión del clasificador lineal está definida por la función $x^{(1)} + 2x^{(2)} - 3 = 0$, esta ecuación representa una recta que separa el plano en 2 regiones de clasificación. El vector de pesos $w = [1, 2]^T$ determina la orientación de la recta, mientras $b = -3$ representa el sesgo.

1.2 Actualización del Perceptrón:

$w_{nuevo} = w + \eta y_i x_i \quad ; \quad b_{nuevo} = b + \eta y_i \quad , \quad \eta > 0$

Margen de Observación $\rightarrow m_i = y_i (w^T x_i + b)$

Para calcular el nuevo margen, debemo utilizar parámetros

La actualización del perceptrón modifica el vector de pesos y el sesgo en función de la observación utilizada y su etiqueta verdadera.

Dado que el incremento del margen es estrictamente positivo, la actualización favorece la clasificación correcta de la observación utilizada, aunque no garantiza que quede correctamente clasificada, después de una sola actualización.

4.3. Ejercicio Numérico.

$w = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$; $b = 0$; $\eta = 0,5$ } Parámetros iniciales

$x = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$; $y = +1$ } Observación

$$f(x) = [0\ 0] \begin{bmatrix} 2 \\ 1 \end{bmatrix} + 0 = 0(2) + 0(1) + 0 = 0$$

Predicción dada: $\hat{y} = \begin{cases} +1 & f(x) > 0 \leftrightarrow 0 > 0 \rightarrow \text{falso} \\ -1 & f(x) \leq 0 \leftrightarrow 0 \leq 0 \rightarrow \text{Verdadero} \end{cases}$

Entonces $y = -1$, sin embargo, la etiqueta verdadera es: $y = +1$, por lo que: $\hat{y} \neq y$.

La observación está mal clasificada y, por lo tanto, hay que aplicar la regla de actualización del perceptrón. La igualdad debe respetar la condición que cuando $f(x) = 0$ la clase predicha es -1 y no $+1$.

$$w_N = w + \eta y x \leftrightarrow w_N = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + (0,5)(+1) \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0,5 \end{bmatrix}$$

Nuevo Sesgo $\leftrightarrow$ $b_{nuevo} = b + \eta y = 0 + (0,5)(+1) = 0,5$

$w_{nuevo} = \begin{bmatrix} 1 \\ 0,5 \end{bmatrix}$; $b_{nuevo} = 0,5$

Margen inicial $\rightarrow$ $m = y(w^T x + b)$

$$m = (+1)\left(\begin{bmatrix}0 & 0\end{bmatrix}\begin{bmatrix}2\\1\end{bmatrix} + 0\right) = (+1)[0(2) + 0(1) + 0] = 0$$

El resultado indica que inicialmente la observación se encuentra en la frontera, sobre la frotera de decisión.

$$m_N = y(w_{nuevo}^T x + b_{nuevo}) = (+1)\left(\begin{bmatrix}1 & 0{,}5\end{bmatrix}\begin{bmatrix}2\\1\end{bmatrix} + 0{,}5\right)$$

$$m_N = (+1)[1(2) + 0{,}5(1) + 0{,}5] = (+1)(3) = 3$$

Verificación $\rightarrow$ $m_{nuevo} = m + \eta(\|x\|_2^2 + 1) = 0 + 0{,}5(5+1)$

$\|x\|_2^2 = 2^2 + 1^2 = 5$ $\}$ $m_{nuevo} = 0{,}5(6) = 3$ $\}$ Coincide

Al aplicar la regla de actualización con una tasa de aprendizaje de $\eta = 0{,}5$, entonces: $w_{nuevo} = \begin{bmatrix}1\\0{,}5\end{bmatrix}$, $b_{nuevo} = 0{,}5$ y el margen aumenta de 0 a 3. Este resultado coincide con lo demostrado antes y confirma que basta con una sola actualización para corregir su clasificación en este caso.

2. Clasificacion de los K vecinos mas cercanos (K-NN)

considere una observación nueva $q = (1,1)$ y el siguiente conjunto de entrenamiento:

observación	x_1	x_2	x_3	x_4	x_5
	(0,0)	(1,0)	(3,1)	(0,3)	(1.1, 1.1)
	A	A	B	B	B

use la distancia euclidiana $d(q, x_i) = \sqrt{(q_1 - x_{i,1})^2 (q_2 - x_{i,2})^2}$ y la votación mayoritaria de los K vecinos mas proximos

2.1 Calcule las cinco distancias y ordene las observaciones desde las mas cercanas hasta la mas lejana Clasifique q utilizando $K=1$, $K=3$ y $K=5$. Explique porque el valor de K puede cambiar la predicción

Distancia a $x_1 = (0,0)$: $d(q, x_1) = \sqrt{(1-0)^2 + (1-0)^2}$

$= \sqrt{1+1} = \sqrt{2} = 1.4142$

Distancia a $x_2 = (1,0)$: $d(q, x_2) = \sqrt{(1-1)^2 + (1-0)^2}$

$= \sqrt{0+1} = 1$

Distancia a $x_3 = (3,1)$: $d(q, x_3) = \sqrt{(1-3)^2 (1-1)^2}$

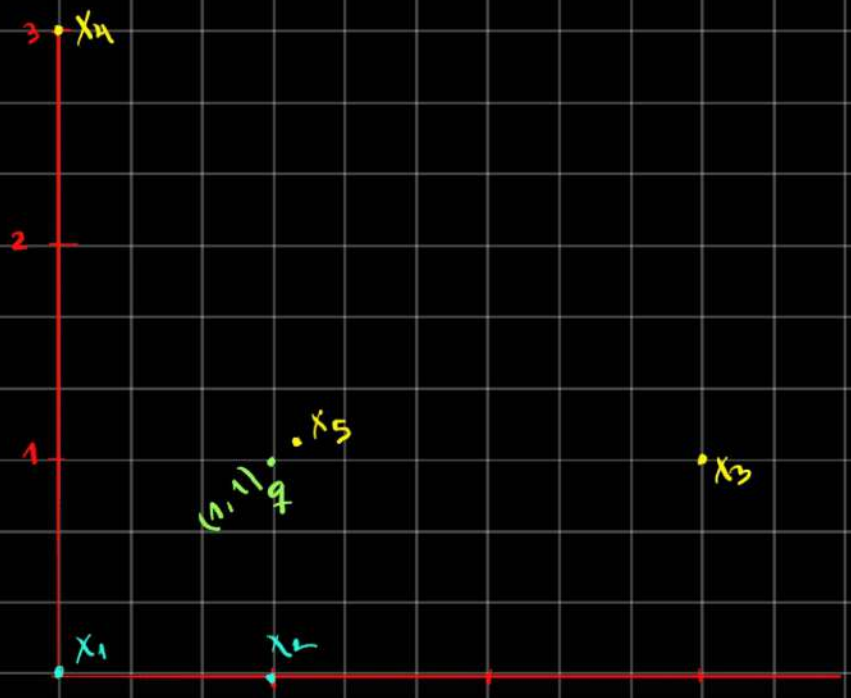
$= \sqrt{4+0} = 2$

Distancia a $X_4 = (0,3)$: $d(q, X_4) = \sqrt{(1-0)^2 + (1-3)^2}$

$= \sqrt{1+4} = \sqrt{5} = 2.2361$

Distancia a $X_5 = (1.1, 1.1)$: $d(q, X_5) = \sqrt{(1-1.1)^2 (1-1.1)^2}$

$= \sqrt{0,01 + 0,01} = 0,1414$



- Para $K=1$: se considera unicamente X_5, que pertenece a B. Por tanto, $\hat{y} = B$
- Para $K=3$: se consideran X_5, X_2, X_1. Hay dos votos A y uno B. Por tanto, $\hat{y} = A$
- Para $K=5$: Se consideran las cinco observaciones. Hay tres votos B y dos A. Por tanto $\hat{y} = B$

conclusión

El valor de K modifica la prediccion porque determina cuantos vecinos participan en la votación. cuando $K=1$, la decisión depende exclusivamente del

punto mas cercano; con $K=3$, la clase A obtiene la mayoria; y con $K=5$, la clase B vuelve a predominar. Esto demuestra que la eleccion de K influye directamente en el comportamiento del clasificador.

3. Evaluación de un Clasificador Binario:

$y = [0, 0, 0, 0, 1, 1, 1, 1, 1, 1]$ ← Etiquetas Verdaderas

$\hat{y} = [0, 1, 0, 0, 1, 0, 1, 1, 0, 1]$ → Predicciones

3.1 Matriz de Confusión.

$$C_{ab} = \sum_{i=1}^{N} 1(y_i = a \wedge \hat{y}_i = b)$$

Permite comparar las etiquetas verdaderas de las observaciones con las etiquetas predichas por un clasificador.

$a \in \{0, 1\}$ Clase Real

$b \in \{0, 1\}$ Clase Predicha

Norma

$N = 10$; Utilizando el orden de las clases $(0, 1)$

$$C = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$$ Filas Clases Reales
Columnas clases Predichas

$TN \rightarrow y_i = 0 ; \hat{y}_i = 0 \rightarrow$ Verdaderos Negativos
$FP \rightarrow y_i = 0 ; \hat{y}_i = 1 \rightarrow$ Falsos Positivos
$FN \rightarrow y_i = 1 ; \hat{y}_i = 0 \rightarrow$ Falsos Negativos
$TP \rightarrow y_i = 1 ; \hat{y}_i = 1 \rightarrow$ Verdaderos Positivos

Observación	Etiqueta Real	Predicción	Clasificación
1	0	0	TN
2	0	1	FP
3	0	0	TN
4	0	0	TN
5	1	1	TP
6	1	0	FN
7	1	1	TP
8	1	1	TP
9	1	0	FN
10	1	1	TP

Para TN:
$$TN = \sum_{i=1}^{N} 1(y_i = 0 \wedge \hat{y}_i = 0)$$

Esto se cumple para la observación: 1, 3 y 4
$i \in \{1, 3, 4\}$, por tanto $TN = 1 + 1 + 1 = 3$

Para FP:
$$FP = \sum_{i=1}^{N} 1(y_i = 0 \wedge \hat{y}_i = 1) \; ; \; i \in \{2\}$$

Se cumple únicamente para $2 \rightarrow FP = 1$

Para FN:
$$FN = \sum_{i=1}^{N} 1(y_i = 1 \wedge \hat{y}_i = 0) \; ; \; i \in \{6, 9\}$$

3.2. Métricas

$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$; $Precision = \frac{TP}{TP + FP}$

$Recall = \frac{TP}{TP + FN}$; $F_1 = 2\,\frac{Precisión \cdot Recall}{precisión + Recall}$

$N = TP + TN + FP + FN$ ∴ $Accuracy = \frac{TP + TN}{N} = \frac{7}{10} = 0,7$

$Accuracy = 0,7 \cdot 100\% = 70\%$ ⟷ Exactitud del 70%.

Esta métrica permite evaluar el rendimiento global del clasificador.

$Precision = \frac{TP}{TP + FP} = \frac{4}{6} = 0,8 \rightarrow 80\%$ } Predicciones positivas

Significa que el 80% de las predicciones fueron correctas, y el 20% correspondió a falsos positivos.

$Recall = \frac{TP}{TP + FN} = \frac{4}{6} = \frac{2}{3} = 0,666 \times 100\% = 66,67\%$

Sensibilidad ↗

Significa que el modelo detectó aproximadamente el 66,67% de las observaciones positivas mientras que el 33,33% fue clasificado incorrectamente negativo.

$F_1 = 2\,\frac{Precision \cdot Recall}{Precision + Recall} = 2\,\frac{(4/5)(2/3)}{(4/5) + (2/3)} = \frac{8}{11} = 0,7273$

$F_1 = 72,73\%$

F1-score no representa una proporción de observaciones acertadas. F1 permite evaluar conjuntamente la presición y la sensibilidad, penalicando desequilibrios entre ellas, es decir, f1 resume el equilibrio entre Precisson y Recall.

$FN = 1+1 = 2$ ⟷ Clasificación incorrecta, dos observaciones que pertenecían a la clase positiva.

Para TP:

$$TP = \sum_{i=1}^{N} 1(y_i = 1 \wedge \hat{y}_i = 1) \; ; \; i \in \{5, 7, 8, 10\}$$

$TP = 1+1+1+1 = 4$

$$C = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$$

$TN = 3$, $FP = 1$, $FN = 2$ y $TP = 4$ ⟷ $C = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}$

Los elementos de la diagonal representan predicciones correctas, los elementos fuera representan errores de clasificación

Número de Observaciones Realmente Negativas:

El vector de etiquetas Verdaderas dice $N_0 = 4$

$N_0 = TN + FP$ } Verdaderos negativos y falsos positivos

$N_0 = 3+1 = 4$

Número de Observaciones Realmente Positivas:

Se ven 6 observaciones de clase 1 $N_1 = 6$

$N_1 = FN + TP$

$N_1 = 2+4$

$N_1 = 6$

Predicciones: $\hat{N}_0 = TN + FN = 3+2 = 5$ } 10

$\hat{N}_1 = FP + TP = 1+4 = 5$

El clasificador logró siete predicciones correctas y tres incorrectas.