Ingeniería Electrónica

Teoría de Aprednizaje de Máquinas

# PARCIAL: Métodos kernel, espacios de características y formulación matricial

**Estudiante:** Phillip Santiago Adarmes Aldana y Juan José García Trujillo

**Asignatura:** Teoría de Aprendizaje de Máquinas

**Programa:** Ingeniería Electrónica

29 de octubre de 2026

# Índice

**1. Regresión en un espacio de características** **2**
1.1. Mínimos cuadrados. . . . . 2
1.2. Mínimos cuadrados regularizados . . . . . 15
1.3. Estimación por máxima verosimilitud . . . . . 20
1.4. Máximo a posteriori (MAP) . . . . . 25
1.5. Implementación y análisis. . . . . 33

**2. Espacios RKHS, embeddings de media y discrepancia entre distribuciones.** **35**
2.1. Definición rigurosa del embedding de media . . . . . 35
2.2. Pertenencia al RKHS e interpretación geométrica . . . . . 37
2.3. Discrepancia máxima de medias (MMD) . . . . . 41
2.4. Implementación con MNIST y Fashion-MNIST . . . . . 51

**3. Índice de correlación de Pearson: espacio original y RKHS.** **53**
3.1. Coeficiente de Pearson en el espacio original. . . . . 53

# 1 Regresión en un espacio de características

## 1.1 Mínimos cuadrados.

### a) Obtención de la función objetivo de mínimos cuadrados

**Planteamiento del problema**

Considérese un conjunto de datos de entrenamiento formado por $N$ observaciones, representado mediante el conjunto

$$\mathcal{D} = \{(x_n, t_n)\}_{n=1}^{N},$$

donde $x_n \in \mathbb{R}^P$ corresponde al vector de características de la observación $n$, y $t_n \in \mathbb{R}$ representa el valor objetivo asociado a dicha observación. El parámetro $N$ indica el número total de observaciones, mientras que $P$ corresponde al número de características de entrada.

El objetivo de la regresión consiste en construir un modelo que permita estimar el valor objetivo $t_n$ a partir de las características $x_n$. Para ello, se introduce una transformación de características, definida como

$$\phi : \mathbb{R}^P \longrightarrow \mathbb{R}^Q,$$

la cual transforma cada vector de entrada $x_n$, originalmente perteneciente a un espacio de dimensión $P$, en un vector de características transformadas de dimensión $Q$:

$$\phi(x_n) = \begin{bmatrix} \phi_1(x_n) \\ \phi_2(x_n) \\ \vdots \\ \phi_Q(x_n) \end{bmatrix} \in \mathbb{R}^Q.$$

Cada función $\phi_q(x_n)$ representa una característica transformada de la observación $n$. Esta transformación permite incorporar relaciones no lineales entre las variables originales mediante un modelo que continúa siendo lineal respecto a sus parámetros.

**Definición del modelo de regresión**

Una vez definida la transformación de características, se establece el modelo de regresión lineal en el espacio transformado:

$$\boxed{t_n = \phi(x_n)^T w + \eta_n}$$

donde $w \in \mathbb{R}^Q$ es el vector de parámetros del modelo y $\eta_n$ representa el término de error asociado a la observación $n$.

El vector de parámetros se expresa como

$$w = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_Q \end{bmatrix} \in \mathbb{R}^Q.$$

Por su parte, la transpuesta del vector de características transformadas es

$$\phi(x_n)^T = \begin{bmatrix} \phi_1(x_n) & \phi_2(x_n) & \cdots & \phi_Q(x_n) \end{bmatrix}.$$

Al desarrollar el producto matricial $\phi(x_n)^T w$, se obtiene

$$\phi(x_n)^T w = \sum_{q=1}^{Q} \phi_q(x_n) w_q.$$

**Propiedad utilizada:** definición del producto entre un vector fila y un vector columna. El producto de un vector fila de dimensión $1 \times Q$ por un vector columna de dimensión $Q \times 1$ produce un escalar, equivalente a la suma de los productos de sus componentes correspondientes.

En consecuencia, el modelo también puede expresarse como

$$\boxed{t_n = \sum_{q=1}^{Q} \phi_q(x_n) w_q + \eta_n}$$

La expresión anterior indica que la predicción del modelo se obtiene mediante una combinación lineal de las características transformadas, ponderadas por los parámetros $w_q$, a la cual se incorpora el término de error $\eta_n$.

Para simplificar la notación, se define la predicción de la observación $n$ como

$$\hat{t}_n = \phi(x_n)^T w.$$

Por tanto, el modelo puede escribirse como

$$t_n = \hat{t}_n + \eta_n.$$

Despejando el término de error, se obtiene

$$\boxed{\eta_n = t_n - \hat{t}_n = t_n - \phi(x_n)^T w}$$

**Propiedad utilizada:** igualdad algebraica y operación inversa de la suma. Al restar la predicción $\hat{t}_n$ en ambos lados de la ecuación, se aísla el término de error. Así, el error corresponde a la diferencia entre el valor observado y el valor predicho por el modelo.

**Definición del error para el conjunto de datos**

El propósito del ajuste consiste en determinar el vector de parámetros $w$ que permita obtener predicciones cercanas a los valores objetivo observados. Para cuantificar la diferencia entre los valores reales y las predicciones, se define el error residual de cada observación como

$$e_n(w) = t_n - \phi(x_n)^T w.$$

Como el conjunto de entrenamiento contiene $N$ observaciones, existe un residual asociado a cada una de ellas. Por consiguiente, el ajuste del modelo debe considerar los errores de todas las observaciones, y no únicamente el error de un dato individual.

Una primera posibilidad consiste en sumar los residuos:

$$\sum_{n=1}^{N} e_n(w).$$

Sin embargo, esta expresión no constituye una medida adecuada del error total, debido a que los residuos positivos y negativos pueden compensarse entre sí. Por ejemplo, dos residuos de valores 3 y $-3$ producen una suma igual a cero, aunque ambas predicciones presentan errores distintos de cero.

Para evitar esta compensación, se considera el cuadrado de cada residual:

$$e_n(w)^2 = \left(t_n - \phi(x_n)^T w\right)^2.$$

**Propiedad utilizada:** no negatividad del cuadrado de un número real. Para todo $e_n(w) \in \mathbb{R}$, se cumple que

$$e_n(w)^2 \geq 0,$$

y la igualdad se alcanza únicamente cuando $e_n(w) = 0$. Por tanto, elevar los residuos al cuadrado evita que los errores positivos y negativos se cancelen y permite cuantificar la magnitud de las discrepancias.

Al sumar los errores cuadrados de las $N$ observaciones, se obtiene la suma de cuadrados de los errores residuales:

$$\text{SSE}(w) = \sum_{n=1}^{N} \left(t_n - \phi(x_n)^T w\right)^2.$$

Esta expresión depende del vector de parámetros $w$, puesto que las predicciones $\phi(x_n)^T w$ cambian al modificar sus componentes. En consecuencia, la suma de cuadrados de los errores residuales puede utilizarse como una función que cuantifica el error total del modelo para cada posible elección de sus parámetros.

**Formulación de la función objetivo**

El método de mínimos cuadrados determina los parámetros que minimizan la suma de los cuadrados de los residuos. En términos matemáticos, el problema consiste en encontrar el vector $w$ para el cual la función $\text{SSE}(w)$ alcanza su menor valor posible.

Por tanto, la función objetivo de mínimos cuadrados se define como

$$\boxed{J(w) = \sum_{n=1}^{N} \left(t_n - \phi(x_n)^T w\right)^2}$$

y el problema de optimización correspondiente queda formulado como

$$\boxed{\hat{w}_{\text{LS}} = \arg\min_{w \in \mathbb{R}^Q} \sum_{n=1}^{N} \left(t_n - \phi(x_n)^T w\right)^2}$$

donde $\hat{w}_{\text{LS}}$ representa el vector de parámetros estimado mediante el método de mínimos cuadrados, y el subíndice LS proviene de *Least Squares*.

**Propiedad utilizada:** definición del operador de minimización y del argumento mínimo. La expresión $\min_w J(w)$ representa el menor valor que puede alcanzar la función objetivo, mientras que $\arg\min_w J(w)$ identifica el valor o los valores de $w$ que producen dicho mínimo.

En esta formulación, el vector $w$ constituye la variable de optimización, mientras que los datos de entrenamiento y la transformación $\phi$ se consideran conocidos. El procedimiento busca, por tanto, los parámetros que minimizan la suma de los errores residuales elevados al cuadrado.

**Expresión matricial de la función objetivo**

Para expresar la función objetivo de manera compacta, se construye la matriz de diseño $\Phi$, cuyas filas contienen los vectores de características transformadas correspondientes a cada observación:

$$\Phi = \begin{bmatrix} \phi(x_1)^T \\ \phi(x_2)^T \\ \vdots \\ \phi(x_N)^T \end{bmatrix} = \begin{bmatrix} \phi_1(x_1) & \cdots & \phi_Q(x_1) \\ \phi_1(x_2) & \cdots & \phi_Q(x_2) \\ \vdots & \ddots & \vdots \\ \phi_1(x_N) & \cdots & \phi_Q(x_N) \end{bmatrix}.$$

Como existen $N$ observaciones y $Q$ características transformadas, las dimensiones de esta matriz son

$$\Phi \in \mathbb{R}^{N \times Q}.$$

A continuación, se agrupan los valores objetivo en el vector

$$t = \begin{bmatrix} t_1 \\ t_2 \\ \vdots \\ t_N \end{bmatrix} \in \mathbb{R}^N,$$

y se define el vector de residuos como

$$e(w) = t - \Phi w.$$

**Propiedad utilizada:** definición del producto matriz-vector. Puesto que $\Phi \in \mathbb{R}^{N \times Q}$ y $w \in \mathbb{R}^Q$, el producto $\Phi w$ está definido y pertenece a $\mathbb{R}^N$. Su componente $n$-ésima es precisamente $\phi(x_n)^T w$. Por ello, la resta $t - \Phi w$ produce un vector de $N$ residuos.

La función objetivo puede expresarse ahora como la suma de los cuadrados de las componentes de $e(w)$:

$$J(w) = \sum_{n=1}^{N} e_n(w)^2.$$

**Propiedad utilizada:** definición de la norma euclidiana al cuadrado. Para un vector $v \in \mathbb{R}^N$, la norma euclidiana se define mediante

$$\|v\|_2 = \sqrt{\sum_{n=1}^{N} v_n^2}.$$

Al elevar ambos lados al cuadrado, resulta

$$\|v\|_2^2 = \sum_{n=1}^{N} v_n^2.$$

Aplicando esta definición al vector de residuos $e(w) = t - \Phi w$, se obtiene

$$J(w) = \|e(w)\|_2^2.$$

Finalmente, al sustituir la definición del vector de residuos, la función objetivo adopta su forma matricial:

$$\boxed{J(w) = \|t - \Phi w\|_2^2}$$

Por consiguiente, el problema de mínimos cuadrados también puede escribirse como

$$\boxed{\hat{w}_{\text{LS}} = \underset{w \in \mathbb{R}^Q}{\arg\,\min} \|t - \Phi w\|_2^2}$$

Esta última expresión constituye la formulación matricial de la función objetivo de mínimos cuadrados. Su equivalencia con la formulación mediante sumatoria se debe a que la norma euclidiana al cuadrado corresponde exactamente a la suma de los cuadrados de las componentes del vector de residuos.

"'latex

**b) Desarrollo de la ecuación de mínimos cuadrados**

**Función objetivo y objetivo de la optimización**

A partir de la función objetivo obtenida en la sección anterior, el problema de mínimos cuadrados se expresa como

$$J(w) = \|t - \Phi w\|_2^2,$$

donde $t \in \mathbb{R}^N$ es el vector de valores objetivo, $\Phi \in \mathbb{R}^{N \times Q}$ es la matriz de diseño y $w \in \mathbb{R}^Q$ es el vector de parámetros que debe estimarse.

El propósito consiste en encontrar el vector $\hat{w}_{\text{LS}}$ que minimiza la función $J(w)$. Para obtener una expresión analítica de dicho vector, se desarrolla la función objetivo y se calcula su gradiente respecto a $w$. Posteriormente, se iguala el gradiente a cero para determinar los puntos estacionarios.

**Desarrollo de la norma euclidiana al cuadrado**

La función objetivo está definida mediante la norma euclidiana al cuadrado del vector residual. Por definición, para cualquier vector $v \in \mathbb{R}^N$, se cumple que

$$\|v\|_2^2 = v^T v.$$

**Propiedad utilizada:** definición de la norma euclidiana mediante el producto interno. La norma euclidiana al cuadrado de un vector es igual al producto interno del vector consigo mismo. En consecuencia, la función objetivo puede reescribirse como

$$J(w) = (t - \Phi w)^T (t - \Phi w).$$

Para desarrollar esta expresión, se aplica la propiedad distributiva del producto matricial respecto de la suma y la resta. En particular, para matrices y vectores de dimensiones compatibles,

$$(A - B)^T = A^T - B^T.$$

Por tanto,

$$J(w) = (t^T - (\Phi w)^T)(t - \Phi w).$$

**Propiedad utilizada:** transpuesta de un producto matricial. La transpuesta de un producto invierte el orden de los factores:

$$(AB)^T = B^T A^T.$$

Aplicando esta propiedad a $\Phi w$, se obtiene

$$(\Phi w)^T = w^T \Phi^T.$$

Al sustituir esta igualdad en la expresión anterior, resulta

$$J(w) = (t^T - w^T \Phi^T)(t - \Phi w).$$

**Aplicación de la propiedad distributiva**

Se aplica la propiedad distributiva del producto matricial sobre los dos términos de cada factor. Esto produce cuatro términos:

$$\begin{aligned} J(w) = t^T t - t^T \Phi w \\ - w^T \Phi^T t + w^T \Phi^T \Phi w. \end{aligned}$$

Cada término se obtiene al multiplicar un elemento del primer factor por un elemento del segundo factor, respetando el orden de los factores matriciales.

**Propiedad utilizada:** distributividad del producto matricial. Para matrices y vectores de dimensiones compatibles, se cumple que

$$(A + B)C = AC + BC,$$

$$A(B + C) = AB + AC.$$

Estas propiedades permiten desarrollar productos de sumas y diferencias, de manera análoga a la distributividad del producto algebraico escalar.

Los términos $t^T \Phi w$ y $w^T \Phi^T t$ pueden simplificarse debido a que ambos son escalares. En efecto, las dimensiones de los factores son

$$t^T \Phi w: \quad (1 \times N)(N \times Q)(Q \times 1) \longrightarrow 1 \times 1,$$

mientras que

$$w^T \Phi^T t: \quad (1 \times Q)(Q \times N)(N \times 1) \longrightarrow 1 \times 1.$$

**Propiedad utilizada:** un escalar es igual a su transpuesta. Si $a \in \mathbb{R}$, entonces $a^T = a$. En particular,

$$(t^T \Phi w)^T = t^T \Phi w.$$

Por la propiedad de la transpuesta de un producto,

$$(t^T \Phi w)^T = w^T \Phi^T t.$$

Por consiguiente,

$$\boxed{t^T \Phi w = w^T \Phi^T t}.$$

Esta igualdad permite combinar los dos términos cruzados de la función objetivo. De este modo, la expresión desarrollada se reduce a

$$\boxed{J(w) = t^T t - 2 w^T \Phi^T t + w^T \Phi^T \Phi w}$$

Esta forma de la función objetivo facilita el cálculo de las derivadas respecto al vector de parámetros $w$.

**Cálculo del gradiente de la función objetivo**

El gradiente de una función escalar respecto a un vector contiene las derivadas parciales de la función respecto a cada componente del vector. Para la función $J(w)$, se define como

$$\nabla_w J(w) = \begin{bmatrix} \frac{\partial J}{\partial w_1} \\ \frac{\partial J}{\partial w_2} \\ \vdots \\ \frac{\partial J}{\partial w_Q} \end{bmatrix}.$$

Dado que $J(w)$ es una función escalar de $w \in \mathbb{R}^Q$, su gradiente es un vector de dimensión $Q \times 1$.

A partir de la expresión desarrollada,

$$J(w) = t^T t - 2w^T \Phi^T t + w^T \Phi^T \Phi w,$$

se calcula el gradiente derivando cada término por separado.

**Derivada del primer término**

El primer término es

$$t^T t.$$

Como $t$ y $\Phi$ representan datos conocidos, ninguno depende de $w$. Por tanto, $t^T t$ es constante respecto al vector de parámetros.

**Propiedad utilizada:** derivada de una constante. La derivada de una constante respecto a cualquier variable es cero. En consecuencia,

$$\boxed{\nabla_w (t^T t) = 0}$$

**Derivada del segundo término**

El segundo término es

$$-2w^T \Phi^T t.$$

Se define, para simplificar la notación, el vector constante

$$a = \Phi^T t \in \mathbb{R}^Q.$$

Así, el término puede expresarse como

$$-2w^T a.$$

Al desarrollar el producto entre el vector fila $w^T$ y el vector columna $a$, se obtiene

$$w^T a = \sum_{q=1}^{Q} w_q a_q.$$

Por tanto,

$$-2w^T a = -2 \sum_{q=1}^{Q} w_q a_q.$$

Al derivar respecto a cada componente $w_j$, todos los términos que contienen $w_q$, con $q \neq j$, tienen derivada cero respecto a $w_j$, mientras que el término que contiene $w_j$ tiene derivada $a_j$.

**Propiedad utilizada:** derivada de una función lineal. Para una constante $c$,

$$\frac{d}{dx}(cx) = c.$$

En consecuencia, para cada componente $w_j$,

$$\frac{\partial}{\partial w_j}\left(-2\sum_{q=1}^{Q} w_q a_q\right) = -2a_j.$$

Al reunir las derivadas parciales en forma vectorial,

$$\nabla_w(-2w^T a) = -2a.$$

Finalmente, al sustituir $a = \Phi^T t$, se obtiene

$$\boxed{\nabla_w(-2w^T\Phi^T t) = -2\Phi^T t}$$

**Derivada del tercer término**

El tercer término corresponde a la expresión cuadrática

$$w^T\Phi^T\Phi w.$$

Para simplificar su derivación, se define la matriz

$$A = \Phi^T\Phi \in \mathbb{R}^{Q\times Q}.$$

Por tanto, el término cuadrático puede escribirse como

$$w^T A w.$$

**Propiedad utilizada:** derivada de una forma cuadrática. Para una matriz constante $A \in \mathbb{R}^{Q\times Q}$ y un vector $w \in \mathbb{R}^Q$, se cumple que

$$\boxed{\nabla_w(w^T A w) = (A + A^T)w}$$

Esta identidad se obtiene al expresar la forma cuadrática como una suma de componentes:

$$w^T A w = \sum_{i=1}^{Q}\sum_{j=1}^{Q} w_i A_{ij} w_j.$$

Al derivar respecto a $w_k$, la variable $w_k$ aparece tanto en el primer factor $w_i$ cuando $i = k$, como en el último factor $w_j$ cuando $j = k$. Por la regla del producto, se obtienen las dos contribuciones:

$$\frac{\partial}{\partial w_k}(w^T A w) = \sum_{j=1}^{Q} A_{kj} w_j + \sum_{i=1}^{Q} w_i A_{ik}.$$

La primera suma corresponde a la componente $k$ de $Aw$, mientras que la segunda corresponde a la componente $k$ de $A^T w$. Al agrupar las derivadas parciales en un vector, resulta

$$\nabla_w(w^T A w) = Aw + A^T w = (A + A^T)w.$$

En el problema de mínimos cuadrados, $A = \Phi^T\Phi$. Esta matriz es simétrica, ya que

$$A^T = (\Phi^T\Phi)^T.$$

Aplicando la propiedad de la transpuesta de un producto,

$$A^T = \Phi^T(\Phi^T)^T.$$

Como la transpuesta de la transpuesta de una matriz es la matriz original,

$$(\Phi^T)^T = \Phi,$$

se obtiene

$$A^T = \Phi^T\Phi = A.$$

Por tanto, $A + A^T = 2A$, y la derivada de la forma cuadrática se simplifica a

$$\nabla_w(w^T A w) = 2Aw.$$

Al sustituir $A = \Phi^T\Phi$, resulta

$$\boxed{\nabla_w(w^T\Phi^T\Phi w) = 2\Phi^T\Phi w}$$

**Obtención del gradiente completo**

Las derivadas obtenidas para cada término de la función objetivo son

$$\nabla_w(t^T t) = 0,$$

$$\nabla_w(-2w^T\Phi^T t) = -2\Phi^T t,$$

$$\nabla_w(w^T\Phi^T\Phi w) = 2\Phi^T\Phi w.$$

**Propiedad utilizada:** linealidad de la derivación. La derivada de una suma de funciones es igual a la suma de sus derivadas. Por consiguiente, el gradiente de $J(w)$ se obtiene sumando los gradientes de sus tres términos:

$$\nabla_w J(w) = 0 - 2\Phi^T t + 2\Phi^T\Phi w.$$

Así, el gradiente de la función objetivo de mínimos cuadrados es

$$\boxed{\nabla_w J(w) = 2\Phi^T\Phi w - 2\Phi^T t}$$

**Condición de primer orden: igualación del gradiente a cero**

Para determinar los puntos estacionarios de la función objetivo, se iguala el gradiente al vector cero:

$$\nabla_w J(w) = 0.$$

Al sustituir la expresión del gradiente, se obtiene

$$2\Phi^T\Phi w - 2\Phi^T t = 0.$$

Se dividen ambos lados de la ecuación por 2:

$$\Phi^T\Phi w - \Phi^T t = 0.$$

**Propiedad utilizada:** operaciones equivalentes en ambos miembros de una ecuación. Dividir ambos lados por una constante distinta de cero conserva la igualdad y no modifica las soluciones.

A continuación, se suma $\Phi^T t$ a ambos lados:

$$\Phi^T\Phi w - \Phi^T t + \Phi^T t = \Phi^T t.$$

Como $-\Phi^T t + \Phi^T t = 0$, la ecuación resultante es

$$\boxed{\Phi^T\Phi w = \Phi^T t}$$

Esta expresión se conoce como la ecuación normal del problema de mínimos cuadrados. Es una ecuación matricial lineal en el vector desconocido $w$.

**Despeje del vector de parámetros**

Para despejar $w$ a partir de la ecuación normal,

$$\Phi^T\Phi w = \Phi^T t,$$

se requiere que la matriz $\Phi^T\Phi$ sea invertible. Bajo esta condición, se multiplican ambos lados por su matriz inversa, situada a la izquierda:

$$(\Phi^T\Phi)^{-1}\Phi^T\Phi w = (\Phi^T\Phi)^{-1}\Phi^T t.$$

**Propiedad utilizada:** matriz inversa e identidad. Si una matriz cuadrada $A$ es invertible, entonces

$$A^{-1}A = I,$$

donde $I$ es la matriz identidad de la dimensión correspondiente. En este caso, la matriz $\Phi^T\Phi$ tiene dimensión $Q \times Q$, por lo que su inversa también tiene dimensión $Q \times Q$.

Aplicando esta propiedad,

$$Iw = (\Phi^T\Phi)^{-1}\Phi^T t.$$

Como la matriz identidad no modifica el vector al que multiplica,

$$Iw = w,$$

se obtiene finalmente la expresión explícita del estimador de mínimos cuadrados:

$$\boxed{\hat{w}_{\mathrm{LS}} = (\Phi^T\Phi)^{-1}\Phi^T t}$$

La expresión anterior es válida cuando $\Phi^T\Phi$ es invertible.

“‘latex

**c) Comprobación de existencia y unicidad de la solución de mínimos cuadrados**

**Planteamiento del problema**

La función objetivo del método de mínimos cuadrados está definida por

$$J(w) = \|t - \Phi w\|_2^2,$$

donde $t \in \mathbb{R}^N$ es el vector de valores objetivo, $\Phi \in \mathbb{R}^{N \times Q}$ es la matriz de diseño y $w \in \mathbb{R}^Q$ es el vector de parámetros que se desea estimar.

A partir de la condición de primer orden, obtenida mediante la anulación del gradiente de la función objetivo, se establece la ecuación normal:

$$\boxed{\Phi^T \Phi w = \Phi^T t}$$

Cuando la matriz $\Phi^T \Phi$ es invertible, la solución viene dada por

$$\boxed{\hat{w}_{\text{LS}} = (\Phi^T \Phi)^{-1} \Phi^T t}$$

Sin embargo, esta expresión requiere que la matriz $\Phi^T \Phi$ tenga inversa. Por ello, es necesario analizar las condiciones bajo las cuales existe una solución que minimiza la función objetivo y determinar cuándo dicha solución es única.

**Existencia de la solución**

La existencia de una solución significa que hay al menos un vector $w \in \mathbb{R}^Q$ que alcanza el valor mínimo de la función objetivo:

$$\hat{w}_{\text{LS}} \in \arg\min_{w \in \mathbb{R}^Q} \|t - \Phi w\|_2^2.$$

Para comprobar la existencia, se considera que la función objetivo es una función cuadrática continua y no negativa. En efecto, al desarrollar la norma euclidiana al cuadrado se obtiene

$$J(w) = (t - \Phi w)^T (t - \Phi w).$$

Al aplicar la propiedad distributiva y las propiedades de la transpuesta, resulta

$$J(w) = t^T t - 2 w^T \Phi^T t + w^T \Phi^T \Phi w.$$

La función está definida para todo $w \in \mathbb{R}^Q$ y satisface

$$J(w) = \|t - \Phi w\|_2^2 \geq 0.$$

**Propiedad utilizada:** no negatividad de la norma euclidiana al cuadrado. La suma de los cuadrados de las componentes de un vector nunca puede ser negativa. Por tanto, el valor de la función objetivo está acotado inferiormente por cero.

No obstante, que una función esté acotada inferiormente no garantiza, por sí solo, que alcance su mínimo. Para establecer la existencia en este problema, se utiliza la propiedad de proyección ortogonal sobre un subespacio de dimensión finita.

El conjunto de vectores que pueden obtenerse mediante el producto $\Phi w$ constituye el espacio columna de $\Phi$, denotado por $\text{Col}(\Phi)$. Por definición,

$$\text{Col}(\Phi) = \{\Phi w : w \in \mathbb{R}^Q\} \subseteq \mathbb{R}^N.$$

La función objetivo mide la distancia euclidiana al cuadrado entre el vector $t$ y un vector $\Phi w$ perteneciente a dicho espacio:

$$J(w) = \|t - \Phi w\|_2^2.$$

**Propiedad utilizada:** teorema de proyección ortogonal en espacios de dimensión finita. Para todo vector $t \in \mathbb{R}^N$ y todo subespacio lineal $S \subseteq \mathbb{R}^N$, existe un único vector $p \in S$ que minimiza la distancia euclidiana $\|t-p\|_2$. Este vector es la proyección ortogonal de $t$ sobre $S$.

Al aplicar este resultado al subespacio $S = \text{Col}(\Phi)$, existe un vector $p \in \text{Col}(\Phi)$ que minimiza la distancia a $t$. Como $p$ pertenece al espacio columna de $\Phi$, existe al menos un vector $w \in \mathbb{R}^Q$ tal que

$$p = \Phi w.$$

En consecuencia, existe al menos un vector de parámetros que alcanza el mínimo de la función objetivo.

Por tanto,

$$\boxed{\text{La solución de mínimos cuadrados siempre existe.}}$$

Este resultado no requiere que $\Phi$ tenga rango columna completo ni que $\Phi^T\Phi$ sea invertible. Estas condiciones son necesarias para garantizar la unicidad y utilizar directamente la expresión de la solución mediante la inversa.

**Unicidad de la solución**

La unicidad significa que existe un solo vector de parámetros que minimiza la función objetivo. Para analizar esta propiedad, se considera nuevamente la ecuación normal:

$$\Phi^T\Phi w = \Phi^T t.$$

Si la matriz $\Phi^T\Phi$ es invertible, la ecuación normal tiene una única solución, dada por

$$\hat{w}_{\text{LS}} = (\Phi^T\Phi)^{-1}\Phi^T t.$$

Por consiguiente, la unicidad puede estudiarse a partir de la invertibilidad de la matriz $\Phi^T\Phi$.

**Condición de invertibilidad de $\Phi^T\Phi$**

La matriz $\Phi^T\Phi$ tiene dimensiones $Q \times Q$. Para determinar cuándo es invertible, se analiza su forma cuadrática.

Sea $z \in \mathbb{R}^Q$ un vector arbitrario. Entonces,

$$z^T\Phi^T\Phi z = (\Phi z)^T(\Phi z).$$

**Propiedad utilizada:** transpuesta de un producto matricial. Como $(\Phi z)^T = z^T\Phi^T$, se tiene

$$z^T\Phi^T\Phi z = \|\Phi z\|_2^2.$$

Por la no negatividad de la norma euclidiana,

$$\boxed{z^T\Phi^T\Phi z = \|\Phi z\|_2^2 \geq 0}$$

Esta desigualdad demuestra que $\Phi^T\Phi$ es una matriz semidefinida positiva.

**Definición utilizada:** matriz semidefinida positiva. Una matriz simétrica $A$ es semidefinida positiva si cumple

$$z^T A z \geq 0 \qquad \text{para todo } z.$$

En este caso, la igualdad

$$z^T \Phi^T \Phi z = 0$$

se cumple si y solo si

$$\|\Phi z\|_2^2 = 0.$$

Una norma es cero únicamente cuando el vector correspondiente es el vector nulo. Por tanto,

$$\boxed{z^T \Phi^T \Phi z = 0 \iff \Phi z = 0}$$

El conjunto de vectores que satisfacen $\Phi z = 0$ constituye el espacio nulo de $\Phi$, denotado por $\text{Null}(\Phi)$.

Así, $\Phi^T \Phi$ es definida positiva si y solo si

$$\Phi z \neq 0 \qquad \text{para todo } z \neq 0.$$

Esta condición equivale a que el espacio nulo de $\Phi$ contenga únicamente al vector cero:

$$\text{Null}(\Phi) = \{0\}.$$

Por tanto, $\Phi^T \Phi$ es invertible si y solo si las columnas de $\Phi$ son linealmente independientes.

**Condición de rango columna completo**

**Propiedad utilizada:** equivalencia entre independencia lineal, rango e invertibilidad de la matriz de Gram. Para una matriz $\Phi \in \mathbb{R}^{N \times Q}$, se cumple que

$$\boxed{\Phi^T \Phi \text{ es invertible} \iff \text{rank}(\Phi) = Q}$$

La condición $\text{rank}(\Phi) = Q$ significa que las $Q$ columnas de $\Phi$ son linealmente independientes. En particular, para que esta condición sea posible, debe cumplirse $N \geq Q$.

Cuando las columnas son linealmente independientes, ningún vector no nulo $z$ puede satisfacer $\Phi z = 0$. En consecuencia, $\Phi^T \Phi$ es definida positiva e invertible, y la ecuación normal admite una única solución.

Por tanto, la condición suficiente y necesaria para que el estimador de mínimos cuadrados sea único es

$$\boxed{\text{rank}(\Phi) = Q}$$

En este caso, la solución única se expresa como

$$\boxed{\hat{w}_{\text{LS}} = (\Phi^T \Phi)^{-1} \Phi^T t}$$

“‘latex

## 1.2 Mínimos cuadrados regularizados

**Planteamiento del problema**

El método de mínimos cuadrados permite estimar los parámetros de un modelo de regresión minimizando la suma de los cuadrados de los errores residuales. Sin embargo, cuando el modelo contiene numerosas características o existe dependencia lineal entre las columnas de la matriz de diseño, la estimación de los parámetros puede presentar problemas de estabilidad o no ser única. Además, una solución que minimiza el error sobre los datos de entrenamiento no necesariamente proporciona una buena capacidad de predicción sobre datos no observados.

Para abordar estas dificultades, se introduce el método de mínimos cuadrados regularizados, que incorpora un término de penalización a la función objetivo original. Esta penalización restringe la magnitud de los parámetros del modelo y permite controlar la complejidad de la solución obtenida.

La función objetivo de mínimos cuadrados sin regularización está definida por

$$J(w) = \|t - \Phi w\|_2^2,$$

donde $t \in \mathbb{R}^N$ es el vector de valores objetivo, $\Phi \in \mathbb{R}^{N\times Q}$ es la matriz de diseño y $w \in \mathbb{R}^Q$ es el vector de parámetros.

En el método regularizado, se añade a esta función un término proporcional al cuadrado de la norma euclidiana del vector de parámetros. La nueva función objetivo se define como

$$\boxed{J_\lambda(w) = \|t - \Phi w\|_2^2 + \lambda\|w\|_2^2}$$

donde $\lambda > 0$ es el parámetro de regularización. La función contiene dos términos: el primero mide el error de predicción sobre los datos de entrenamiento, mientras que el segundo penaliza los vectores de parámetros con magnitudes elevadas.

**1. Desarrollo del término de regularización**

La norma euclidiana del vector de parámetros $w$ se define como

$$\|w\|_2 = \sqrt{\sum_{q=1}^{Q} w_q^2}.$$

Al elevar ambos lados al cuadrado, se obtiene

$$\boxed{\|w\|_2^2 = \sum_{q=1}^{Q} w_q^2}$$

**Propiedad utilizada: definición de la norma euclidiana al cuadrado.**

El cuadrado de la norma corresponde a la suma de los cuadrados de las componentes del vector. Por tanto, el término de regularización puede escribirse como

$$\lambda\|w\|_2^2 = \lambda \sum_{q=1}^{Q} w_q^2.$$

Esta expresión muestra que la penalización considera todos los parámetros del modelo. Cada componente $w_q$ contribuye al término de regularización mediante su cuadrado, de manera que los parámetros de mayor magnitud producen una penalización más elevada.

Para expresar este término mediante operaciones matriciales, se utiliza la identidad

$$\|w\|_2^2 = w^T w.$$

En efecto, si

$$w = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_Q \end{bmatrix}, \qquad w^T = \begin{bmatrix} w_1 & w_2 & \cdots & w_Q \end{bmatrix},$$

entonces, por la definición del producto entre un vector fila y un vector columna,

$$w^T w = \begin{bmatrix} w_1 & w_2 & \cdots & w_Q \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_Q \end{bmatrix}.$$

Al desarrollar el producto, resulta

$$w^T w = w_1^2 + w_2^2 + \cdots + w_Q^2.$$

Por consiguiente,

$$\boxed{\lambda \|w\|_2^2 = \lambda w^T w}$$

La función objetivo regularizada puede expresarse entonces como

$$\boxed{J_\lambda(w) = \|t - \Phi w\|_2^2 + \lambda w^T w}$$

Esta formulación permite desarrollar la función objetivo y calcular su gradiente utilizando álgebra matricial.

## 2. Desarrollo de la función objetivo regularizada

A partir de la expresión matricial obtenida, la función objetivo se escribe como

$$J_\lambda(w) = \|t - \Phi w\|_2^2 + \lambda w^T w.$$

Aplicando la definición de la norma euclidiana al cuadrado, se obtiene

$$J_\lambda(w) = (t - \Phi w)^T (t - \Phi w) + \lambda w^T w.$$

Para desarrollar el primer término, se utiliza la propiedad de la transpuesta de un producto:

$$(\Phi w)^T = w^T \Phi^T.$$

Por tanto,

$$J_\lambda(w) = (t^T - w^T \Phi^T)(t - \Phi w) + \lambda w^T w.$$

Al aplicar la propiedad distributiva del producto matricial, resulta

$$\begin{aligned} J_\lambda(w) = t^T t &- t^T \Phi w \\ &- w^T \Phi^T t + w^T \Phi^T \Phi w \\ &+ \lambda w^T w. \end{aligned}$$

Como $t^T \Phi w$ es un escalar, coincide con su transpuesta. En consecuencia,

$$t^T \Phi w = w^T \Phi^T t.$$

Al combinar los dos términos cruzados, se obtiene

$$\boxed{\begin{aligned} J_\lambda(w) = t^T t &- 2 w^T \Phi^T t \\ &+ w^T \Phi^T \Phi w + \lambda w^T w. \end{aligned}}$$

Esta expresión permite calcular el gradiente de la función objetivo respecto al vector de parámetros $w$.

## 3. Cálculo del gradiente de la función objetivo regularizada

El gradiente se obtiene derivando cada término de la función objetivo respecto a $w$:

$$\begin{aligned} J_\lambda(w) = t^T t &- 2 w^T \Phi^T t \\ &+ w^T \Phi^T \Phi w + \lambda w^T w. \end{aligned}$$

**Propiedad utilizada: derivada de una constante.**
Como $t$ no depende de $w$, el término $t^T t$ es constante respecto a los parámetros. Por tanto,

$$\nabla_w (t^T t) = 0.$$

**Propiedad utilizada: derivada de una función lineal.**
Para un vector constante $a$, la derivada de $w^T a$ respecto a $w$ es $a$. En este caso, $a = \Phi^T t$, por lo que

$$\nabla_w (-2 w^T \Phi^T t) = -2 \Phi^T t.$$

**Propiedad utilizada: derivada de una forma cuadrática.**
Para una matriz simétrica $A$, se cumple que

$$\nabla_w (w^T A w) = 2 A w.$$

Dado que la matriz $\Phi^T \Phi$ es simétrica, se obtiene

$$\nabla_w (w^T \Phi^T \Phi w) = 2 \Phi^T \Phi w.$$

Finalmente, el término de regularización es

$$\lambda w^T w.$$

Como $\lambda$ es una constante positiva y la matriz identidad $I_Q$ satisface $w^T w = w^T I_Q w$, se aplica la regla de derivación de una forma cuadrática:

$$\nabla_w(\lambda w^T w) = 2\lambda I_Q w.$$

Dado que $I_Q w = w$, resulta

$$\boxed{\nabla_w(\lambda w^T w) = 2\lambda w}$$

**Propiedad utilizada: linealidad de la derivación.**

El gradiente de una suma es igual a la suma de los gradientes de sus términos. Por tanto, al reunir las derivadas parciales se obtiene

$$\boxed{\nabla_w J_\lambda(w) = -2\Phi^T t + 2\Phi^T \Phi w + 2\lambda w}$$

## 4. Obtención de la ecuación de mínimos cuadrados regularizados

Para encontrar los parámetros que minimizan la función objetivo, se aplica la condición de primer orden, igualando el gradiente al vector cero:

$$\nabla_w J_\lambda(w) = 0.$$

Al sustituir la expresión del gradiente, se obtiene

$$-2\Phi^T t + 2\Phi^T \Phi w + 2\lambda w = 0.$$

Dividiendo ambos lados por 2,

$$-\Phi^T t + \Phi^T \Phi w + \lambda w = 0.$$

Se suma $\Phi^T t$ a ambos lados de la ecuación:

$$\Phi^T \Phi w + \lambda w = \Phi^T t.$$

Para expresar los dos términos del lado izquierdo como un único producto matricial, se utiliza la propiedad de factorización de un factor común. La matriz identidad $I_Q$ permite representar el término $\lambda w$ como un producto de matriz por vector:

$$\lambda w = \lambda I_Q w.$$

Por tanto,

$$\Phi^T \Phi w + \lambda I_Q w = \Phi^T t.$$

Aplicando la propiedad distributiva en sentido inverso, se factoriza $w$:

$$\boxed{(\Phi^T \Phi + \lambda I_Q) w = \Phi^T t}$$

Esta expresión corresponde a la ecuación normal de mínimos cuadrados regularizados.

**5. Despeje del vector de parámetros**

A partir de la ecuación normal regularizada,

$$(\Phi^T\Phi + \lambda I_Q)w = \Phi^T t,$$

se multiplica ambos lados por la inversa de la matriz $\Phi^T\Phi + \lambda I_Q$, siempre que dicha inversa exista:

$$\begin{aligned}(\Phi^T\Phi + \lambda I_Q)^{-1}(\Phi^T\Phi + \lambda I_Q)w \\ = (\Phi^T\Phi + \lambda I_Q)^{-1}\Phi^T t.\end{aligned}$$

**Propiedad utilizada: producto de una matriz inversa por la matriz original.**
Si una matriz cuadrada $A$ es invertible, se cumple que $A^{-1}A = I_Q$. Por tanto, el lado izquierdo se reduce a $I_Q w = w$.

Así, se obtiene la solución cerrada del método de mínimos cuadrados regularizados:

$$\boxed{\hat{w}_{\text{RLS}} = (\Phi^T\Phi + \lambda I_Q)^{-1}\Phi^T t}$$

donde $\hat{w}_{\text{RLS}}$ representa el vector de parámetros estimado mediante mínimos cuadrados regularizados.

**5.1. Justificación de la invertibilidad de la matriz regularizada**

La matriz que debe invertirse es

$$A_\lambda = \Phi^T\Phi + \lambda I_Q.$$

Para comprobar que es invertible cuando $\lambda > 0$, se considera un vector arbitrario $z \in \mathbb{R}^Q$, con $z \neq 0$. Al multiplicar por ambos lados de la matriz, se obtiene

$$z^T A_\lambda z = z^T\Phi^T\Phi z + \lambda z^T I_Q z.$$

Aplicando las propiedades de la norma euclidiana,

$$z^T\Phi^T\Phi z = \|\Phi z\|_2^2$$

y

$$z^T I_Q z = z^T z = \|z\|_2^2.$$

Por tanto,

$$\boxed{z^T A_\lambda z = \|\Phi z\|_2^2 + \lambda\|z\|_2^2}$$

El primer término es no negativo:

$$\|\Phi z\|_2^2 \geq 0.$$

El segundo término es estrictamente positivo, ya que $\lambda > 0$ y $z \neq 0$:

$$\lambda\|z\|_2^2 > 0.$$

En consecuencia,

$$z^T A_\lambda z > 0 \qquad \text{para todo } z \neq 0.$$

**Propiedad utilizada: criterio de matriz definida positiva.**

Una matriz simétrica definida positiva es invertible. Como $A_\lambda$ es simétrica y su forma cuadrática es estrictamente positiva para todo vector no nulo, la matriz es definida positiva e invertible.

Por tanto, para cualquier $\lambda > 0$, la solución regularizada está bien definida:

$$\boxed{\hat{w}_{\text{RLS}} = (\Phi^T\Phi + \lambda I_Q)^{-1}\Phi^T t}$$

Esta propiedad garantiza la unicidad de la solución regularizada, incluso cuando las columnas de $\Phi$ son linealmente dependientes.

### 6. Efecto del parámetro de regularización

El parámetro $\lambda$ determina la intensidad de la penalización aplicada a la magnitud de los parámetros. La función objetivo regularizada es

$$J_\lambda(w) = \underbrace{\|t - \Phi w\|_2^2}_{\text{Error de ajuste}} + \underbrace{\lambda\|w\|_2^2}_{\text{Penalización}} .$$

Cuando $\lambda$ aumenta, se incrementa el peso relativo del término $\|w\|_2^2$ en la función objetivo. En consecuencia, el proceso de optimización penaliza con mayor intensidad los vectores de parámetros de magnitud elevada y favorece soluciones con parámetros de menor magnitud, aunque esto pueda incrementar el error de ajuste sobre los datos de entrenamiento.

Por el contrario, cuando $\lambda$ es positivo, pero cercano a cero, la penalización tiene menor influencia sobre la solución. En ese caso, el comportamiento del método se aproxima al de mínimos cuadrados sin regularización, siempre que este último tenga una solución única. Si $\lambda$ tiende a cero y $\Phi^T\Phi$ es invertible, se cumple que “‘ “‘latex

## 1.3 Estimación por máxima verosimilitud

**Planteamiento probabilístico del modelo**

En las secciones anteriores, los parámetros del modelo de regresión se estimaron mediante la minimización de una función objetivo basada en los errores residuales. En el método de máxima verosimilitud, la estimación de los parámetros se formula desde una perspectiva probabilística: se busca el vector de parámetros que hace más probable observar los valores objetivo del conjunto de entrenamiento.

Se considera el modelo de regresión en el espacio de características:

$$t_n = \phi(x_n)^T w + \eta_n,$$

donde $t_n \in \mathbb{R}$ es el valor objetivo de la observación $n$, $\phi(x_n) \in \mathbb{R}^Q$ es el vector de características transformadas, $w \in \mathbb{R}^Q$ es el vector de parámetros y $\eta_n$ es el término de ruido.

Para obtener el estimador de máxima verosimilitud, se supone que los términos de ruido son variables aleatorias independientes e idénticamente distribuidas, con distribución gaussiana de media cero y varianza $\sigma_\eta^2$:

$$\boxed{\eta_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_\eta^2)}$$

La notación $\mathcal{N}(0, \sigma_\eta^2)$ representa una distribución normal con media cero y varianza $\sigma_\eta^2$. La condición de independencia indica que el ruido de una observación no depende del ruido de las demás, mientras que la condición de distribución idéntica establece que todos los términos de ruido comparten la misma distribución y los mismos parámetros.

Como el valor objetivo satisface $t_n = \phi(x_n)^T w + \eta_n$, el ruido gaussiano implica que, condicionando en las entradas y en los parámetros del modelo, el valor objetivo también sigue una distribución gaussiana:

$$\boxed{t_n \mid x_n, w \sim \mathcal{N}\left(\phi(x_n)^T w, \sigma_\eta^2\right)}$$

**Propiedad utilizada: invariancia de la distribución normal ante traslaciones.**

Si una variable aleatoria $Z$ sigue una distribución normal $\mathcal{N}(\mu, \sigma^2)$, entonces una variable $Y = Z + c$, donde $c$ es una constante, sigue una distribución $\mathcal{N}(\mu + c, \sigma^2)$. En este caso, $\phi(x_n)^T w$ actúa como una media determinada por las características y los parámetros del modelo, mientras que la varianza permanece igual a $\sigma_\eta^2$.

## 1. Construcción de la función de verosimilitud

**Distribución de una observación**

La función de densidad de una variable aleatoria gaussiana de media $\mu$ y varianza $\sigma^2$ está dada por

$$p(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right).$$

Al sustituir la media $\mu = \phi(x_n)^T w$, la varianza $\sigma^2 = \sigma_\eta^2$ y el valor observado $y = t_n$, se obtiene la densidad condicional de la observación $n$:

$$p(t_n \mid x_n, w, \sigma_\eta^2) = \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\left(-\frac{(t_n - \phi(x_n)^T w)^2}{2\sigma_\eta^2}\right).$$

La expresión anterior describe la probabilidad relativa asociada a los valores que puede tomar la variable objetivo, dadas las características de entrada y los parámetros del modelo. Como $t_n$ es una variable continua, técnicamente se trata de una densidad de probabilidad, no de la probabilidad de observar exactamente un valor individual.

**Verosimilitud del conjunto de entrenamiento**

Considérese el conjunto de datos

$$\mathcal{D} = \{(x_n, t_n)\}_{n=1}^N.$$

La función de verosimilitud expresa la densidad conjunta de los valores objetivo observados, condicionada a las entradas y considerada como función de los parámetros $w$:

$$\mathcal{L}(w) = p(t_1, \ldots, t_N \mid X, w, \sigma_\eta^2).$$

**Propiedad utilizada: regla del producto para variables aleatorias independientes.**

Cuando las observaciones son condicionalmente independientes dadas las entradas y los parámetros del modelo, su densidad conjunta es igual al producto de sus densidades individuales. Por tanto,

$$\mathcal{L}(w) = \prod_{n=1}^{N} p(t_n \mid x_n, w, \sigma_\eta^2).$$

Al sustituir la densidad gaussiana de cada observación, se obtiene

$$\mathcal{L}(w) = \prod_{n=1}^{N} \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\left(-\frac{(t_n - \phi(x_n)^T w)^2}{2\sigma_\eta^2}\right).$$

Como la varianza $\sigma_\eta^2$ es común a todas las observaciones, el producto de los factores constantes puede escribirse como

$$\prod_{n=1}^{N} \frac{1}{\sqrt{2\pi\sigma_\eta^2}} = \left(\frac{1}{\sqrt{2\pi\sigma_\eta^2}}\right)^N.$$

Asimismo, se utiliza la propiedad del producto de exponenciales con la misma base:

$$\prod_{n=1}^{N} e^{a_n} = e^{\sum_{n=1}^{N} a_n}.$$

Aplicando ambas propiedades, la función de verosimilitud queda expresada como

$$\mathcal{L}(w) = \left(\frac{1}{\sqrt{2\pi\sigma_\eta^2}}\right)^N \exp\left(-\frac{1}{2\sigma_\eta^2} \sum_{n=1}^{N} (t_n - \phi(x_n)^T w)^2\right).$$

Por consiguiente, la función de verosimilitud del modelo gaussiano es

$$\boxed{\mathcal{L}(w) = (2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_\eta^2} \sum_{n=1}^{N} (t_n - \phi(x_n)^T w)^2\right)}$$

La expresión depende de $w$ a través de la suma de los cuadrados de los residuos. Los demás factores son constantes respecto a los parámetros cuando la varianza del ruido se considera conocida y fija.

## 2. Obtención de la log-verosimilitud

La función de verosimilitud contiene un producto de densidades de probabilidad y una función exponencial. Para facilitar su análisis matemático, se aplica el logaritmo natural a la función de verosimilitud. La función resultante se denomina log-verosimilitud y se define como

$$\ell(w) = \ln \mathcal{L}(w).$$

Al sustituir la expresión de la verosimilitud, se obtiene

$$\ell(w) = \ln\left[(2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_\eta^2} \sum_{n=1}^{N} (t_n - \phi(x_n)^T w)^2\right)\right].$$

**Propiedad utilizada: logaritmo del producto.**

Para dos cantidades positivas $a$ y $b$, se cumple que

$$\ln(ab) = \ln(a) + \ln(b).$$

Además, se utiliza la propiedad del logaritmo de una potencia:

$$\ln(a^b) = b\ln(a),$$

y la identidad

$$\ln(e^u) = u.$$

Al aplicar estas propiedades, la log-verosimilitud se expresa como

$$\begin{aligned}\ell(w) = & -\frac{N}{2}\ln(2\pi\sigma_\eta^2) \\ & -\frac{1}{2\sigma_\eta^2}\sum_{n=1}^{N}(t_n - \phi(x_n)^T w)^2.\end{aligned}$$

Por tanto,

$$\boxed{\ell(w) = -\frac{N}{2}\ln(2\pi\sigma_\eta^2) - \frac{1}{2\sigma_\eta^2}\sum_{n=1}^{N}(t_n - \phi(x_n)^T w)^2}$$

El primer término depende de $N$ y de la varianza del ruido, pero no depende de $w$. El segundo término contiene la suma de los cuadrados de los residuos, que sí depende del vector de parámetros.

**Expresión matricial de la log-verosimilitud**

La suma de los cuadrados de los residuos puede escribirse mediante la norma euclidiana al cuadrado:

$$\sum_{n=1}^{N}(t_n - \phi(x_n)^T w)^2 = \|t - \Phi w\|_2^2.$$

**Propiedad utilizada: equivalencia entre la suma de cuadrados y la norma euclidiana al cuadrado.**

Para cualquier vector $v \in \mathbb{R}^N$,

$$\|v\|_2^2 = \sum_{n=1}^{N} v_n^2.$$

En este caso, el vector de residuos es $t - \Phi w$, cuyas componentes son $t_n - \phi(x_n)^T w$. Por consiguiente, la log-verosimilitud puede expresarse como

$$\boxed{\ell(w) = -\frac{N}{2}\ln(2\pi\sigma_\eta^2) - \frac{1}{2\sigma_\eta^2}\|t - \Phi w\|_2^2}$$

Esta formulación matricial permite establecer directamente la relación entre la estimación por máxima verosimilitud y el método de mínimos cuadrados.

## 3. Obtención del estimador de máxima verosimilitud

El método de máxima verosimilitud determina los parámetros que maximizan la función de verosimilitud del conjunto de observaciones. El estimador se define como

$$\boxed{\hat{w}_{\mathrm{ML}} = \arg\max_{w \in \mathbb{R}^Q} \mathcal{L}(w)}$$

donde el subíndice ML proviene de *Maximum Likelihood*.

**Propiedad utilizada: monotonía estrictamente creciente del logaritmo natural.**

Para números reales positivos, el logaritmo natural conserva el orden de los valores. Por tanto, maximizar una función de verosimilitud positiva equivale a maximizar su logaritmo:

$$\arg\max_{w} \mathcal{L}(w) = \arg\max_{w} \ln \mathcal{L}(w).$$

En consecuencia,

$$\hat{w}_{\mathrm{ML}} = \arg\max_{w \in \mathbb{R}^Q} \ell(w).$$

Al sustituir la expresión de la log-verosimilitud,

$$\hat{w}_{\mathrm{ML}} = \arg\max_{w \in \mathbb{R}^Q} \left[ -\frac{N}{2} \ln(2\pi\sigma_\eta^2) - \frac{1}{2\sigma_\eta^2} \|t - \Phi w\|_2^2 \right].$$

Se supone que la varianza $\sigma_\eta^2 > 0$ es conocida y fija. Por ello, el primer término es constante respecto a $w$, y el factor $1/(2\sigma_\eta^2)$ es estrictamente positivo.

**Propiedad utilizada: invariancia del argumento óptimo ante transformaciones afines con pendiente positiva.**

Si $f(w)$ es una función y $a > 0$, entonces maximizar $c - af(w)$, donde $c$ es constante, equivale a minimizar $f(w)$. En efecto, el término constante no modifica la ubicación del óptimo y la multiplicación por un número negativo invierte el sentido de la optimización.

Aplicando esta propiedad, se obtiene

$$\boxed{\hat{w}_{\mathrm{ML}} = \arg\min_{w \in \mathbb{R}^Q} \|t - \Phi w\|_2^2}$$

Esta expresión coincide con la función objetivo del método de mínimos cuadrados.

A partir de la ecuación normal obtenida en la sección 1.1,

$$\Phi^T \Phi w = \Phi^T t,$$

y suponiendo que $\Phi^T\Phi$ es invertible, se despeja el vector de parámetros mediante la multiplicación por la matriz inversa:

$$(\Phi^T\Phi)^{-1}\Phi^T\Phi w = (\Phi^T\Phi)^{-1}\Phi^T t.$$

Como

$$(\Phi^T\Phi)^{-1}\Phi^T\Phi = I_Q$$

y $I_Q w = w$, resulta

$$\boxed{\hat{w}_{\mathrm{ML}} = (\Phi^T\Phi)^{-1}\Phi^T t}$$

**4. Relación entre máxima verosimilitud y mínimos cuadrados**

La estimación por máxima verosimilitud coincide con la estimación por mínimos cuadrados cuando se cumplen los supuestos de ruido gaussiano, independencia entre las observaciones y varianza común conocida y fija. La equivalencia se obtiene porque, bajo estas condiciones, maximizar la log-verosimilitud equivale a minimizar la suma de los cuadrados de los residuos.

El estimador de mínimos cuadrados se expresa como

$$\hat{w}_{\text{LS}} = \arg\min_{w \in \mathbb{R}^Q} \|t - \Phi w\|_2^2,$$

mientras que el estimador de máxima verosimilitud, bajo el modelo gaussiano establecido, se reduce a

$$\hat{w}_{\text{ML}} = \arg\min_{w \in \mathbb{R}^Q} \|t - \Phi w\|_2^2.$$

Ambos métodos tienen, por tanto, el mismo conjunto de minimizadores:

$$\boxed{\hat{w}_{\text{ML}} = \hat{w}_{\text{LS}}}$$

cuando la solución es única. Si $\Phi^T\Phi$ no es invertible, ambos métodos siguen compartiendo el mismo conjunto de soluciones óptimas, aunque el vector de parámetros óptimo no sea necesariamente único.

La equivalencia no significa que ambos métodos se formulen de la misma manera. El método de mínimos cuadrados parte directamente de una función objetivo que mide el error de predicción, mientras que máxima verosimilitud parte de un modelo probabilístico para las observaciones y determina los parámetros que maximizan la verosimilitud de los datos. La coincidencia entre sus estimadores se deriva de la hipótesis de ruido gaussiano independiente con varianza común fija.

“‘latex

## 1.4 Máximo a posteriori (MAP)

El método de máximo a posteriori (MAP, *Maximum A Posteriori*) permite estimar los parámetros $w$ de un modelo de regresión a partir de los datos observados, incorporando tanto la información proporcionada por estos como el conocimiento previo sobre los parámetros. A diferencia del método de máxima verosimilitud, que determina los parámetros que maximizan la verosimilitud de los datos, el método MAP busca los parámetros que maximizan la distribución posterior. La diferencia fundamental consiste en que el método MAP incorpora una distribución previa que expresa los supuestos probabilísticos establecidos sobre los parámetros antes de observar los datos.

Para desarrollar este método, se considera el modelo de regresión lineal en el espacio de características:

$$t = \Phi w + \eta,$$

donde $t \in \mathbb{R}^N$ es el vector de valores objetivo, $\Phi \in \mathbb{R}^{N \times Q}$ es la matriz de diseño, $w \in \mathbb{R}^Q$ es el vector de parámetros y $\eta \in \mathbb{R}^N$ es el vector de errores aleatorios. Se supone que los errores son independientes y siguen una distribución gaussiana de media cero y varianza $\sigma_\eta^2$. Además, se considera que la matriz de diseño $\Phi$ es conocida, puesto que se construye a partir de las entradas observadas $X$.

## 1. Definición del estimador MAP y aplicación del teorema de Bayes

El objetivo del método MAP es encontrar el vector de parámetros que maximiza la distribución posterior, es decir,

$$\boxed{\hat{w}_{\text{MAP}} = \arg\max_{w} p(w \mid t, X)}$$

En esta expresión, $p(w \mid t, X)$ representa la distribución posterior de los parámetros, condicionada a los datos observados. Para determinarla, se utiliza el teorema de Bayes, que se deriva de la definición de densidad condicional.

Para variables continuas, la densidad condicional se define mediante la relación

$$p(A \mid B) = \frac{p(A, B)}{p(B)},$$

donde $p(A, B)$ es la densidad conjunta de las variables $A$ y $B$, y $p(B)$ es la densidad marginal de la variable condicionante.

Aplicando esta definición al problema de estimación, la distribución posterior de los parámetros puede expresarse como

$$p(w \mid t, X) = \frac{p(w, t \mid X)}{p(t \mid X)}.$$

El término $p(w, t \mid X)$ representa la densidad conjunta de los parámetros y los valores objetivo, condicionada a las entradas observadas. Para desarrollar esta expresión, se utiliza la regla de factorización de densidades conjuntas:

$$p(w, t \mid X) = p(t \mid X, w)p(w \mid X).$$

Esta regla expresa la densidad conjunta como el producto de la densidad de los valores objetivo condicionada a las entradas y los parámetros, por la densidad de los parámetros condicionada a las entradas. En el modelo considerado, se supone que la distribución previa de los parámetros es independiente de las entradas observadas. Por tanto,

$$p(w \mid X) = p(w).$$

Sustituyendo esta igualdad en la factorización de la densidad conjunta, se obtiene

$$p(w, t \mid X) = p(t \mid X, w)p(w).$$

A continuación, al sustituir el resultado en la expresión de la distribución posterior, se obtiene

$$\boxed{p(w \mid t, X) = \frac{p(t \mid X, w)p(w)}{p(t \mid X)}}$$

Esta expresión corresponde al teorema de Bayes aplicado al modelo de regresión. En ella, $p(t \mid X, w)$ es la verosimilitud, $p(w)$ es la distribución previa y $p(t \mid X)$ es la evidencia o probabilidad marginal de los datos. La distribución posterior combina la información de los datos con los supuestos previos sobre los parámetros.

La evidencia se obtiene mediante la ley de la probabilidad total, integrando sobre todos los posibles valores del vector de parámetros:

$$p(t \mid X) = \int_{\mathbb{R}^Q} p(t \mid X, w)p(w)\, dw.$$

Esta integral tiene la función de normalizar la distribución posterior, de manera que su integral respecto a todos los valores posibles de $w$ sea igual a uno:

$$\int_{\mathbb{R}^Q} p(w \mid t, X)\, dw = 1.$$

Como $p(t \mid X)$ depende de los datos observados, pero no de los parámetros $w$, constituye una constante cuando se busca el máximo de la distribución posterior respecto a $w$. Por ello, es posible omitir este denominador al determinar el estimador MAP y trabajar con la expresión proporcional

$$\boxed{p(w \mid t, X) \propto p(t \mid X, w)p(w)}$$

El símbolo $\propto$ significa que una expresión es proporcional a la otra. Indica que una expresión es igual a la otra multiplicada por una constante positiva que no depende de $w$. En este caso, el factor omitido es $1/p(t \mid X)$. La expresión proporcional no representa por sí sola la densidad posterior normalizada, pero conserva el mismo punto de máximo, ya que multiplicar una función positiva por una constante positiva no cambia la posición de su máximo.

## 2. Obtención de la función de verosimilitud

La verosimilitud utilizada en el método MAP se obtiene a partir del modelo de regresión y del supuesto sobre la distribución del ruido. Como se estableció anteriormente, el modelo está definido por

$$t_n = \phi(x_n)^T w + \eta_n,$$

donde $t_n$ es el valor objetivo de la observación $n$, $\phi(x_n)$ es su vector de características y $\eta_n$ es el error aleatorio.

Se supone que los errores siguen una distribución gaussiana independiente e idénticamente distribuida:

$$\eta_n \sim \mathcal{N}(0, \sigma_\eta^2).$$

Por tanto, al sumar el error gaussiano a la predicción determinista $\phi(x_n)^T w$, la distribución condicional del valor objetivo es

$$t_n \mid x_n, w \sim \mathcal{N}\left(\phi(x_n)^T w, \sigma_\eta^2\right).$$

La densidad de una variable aleatoria gaussiana $z \sim \mathcal{N}(\mu, \sigma^2)$ está definida por la fórmula

$$p(z) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(z-\mu)^2}{2\sigma^2}\right).$$

Aplicando esta fórmula a la distribución condicional de $t_n$, se obtiene

$$p(t_n \mid x_n, w) = \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\left(-\frac{(t_n - \phi(x_n)^T w)^2}{2\sigma_\eta^2}\right).$$

Debido a que las observaciones son condicionalmente independientes, la densidad conjunta de todos los valores objetivo es el producto de las densidades individuales:

$$p(t \mid X, w) = \prod_{n=1}^{N} p(t_n \mid x_n, w).$$

Sustituyendo la densidad gaussiana individual en este producto, se obtiene

$$p(t \mid X, w) = \prod_{n=1}^{N} \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\left(-\frac{(t_n - \phi(x_n)^T w)^2}{2\sigma_\eta^2}\right).$$

Al separar los factores constantes de las exponenciales y utilizar la propiedad de que el producto de exponenciales es igual a la exponencial de la suma de sus exponentes, resulta

$$p(t \mid X, w) = (2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_\eta^2} \sum_{n=1}^{N} (t_n - \phi(x_n)^T w)^2\right).$$

La sumatoria representa la suma de los errores cuadráticos de las $N$ observaciones. En notación matricial, esta suma puede expresarse mediante la norma euclidiana al cuadrado:

$$\sum_{n=1}^{N} (t_n - \phi(x_n)^T w)^2 = \|t - \Phi w\|_2^2.$$

Por consiguiente, la función de verosimilitud queda expresada como

$$\boxed{p(t \mid X, w) = (2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2}\right)}$$

Esta es la misma función de verosimilitud desarrollada en el apartado anterior para el método de máxima verosimilitud. En el presente apartado se reutiliza ese resultado, pues la verosimilitud del modelo no cambia por incorporar una distribución previa sobre los parámetros.

### 3. Definición y obtención de la distribución previa de los parámetros

Para aplicar el método MAP es necesario establecer una distribución previa para el vector de parámetros $w$. Esta distribución representa los supuestos probabilísticos sobre los parámetros antes de utilizar los valores objetivo observados. En este desarrollo se adopta una distribución gaussiana multivariante de media cero y matriz de covarianza $\sigma_w^2 I_Q$:

$$\boxed{w \sim \mathcal{N}(0, \sigma_w^2 I_Q)}$$

Esta elección supone que cada parámetro tiene media cero y varianza $\sigma_w^2$, y que los parámetros son independientes entre sí bajo la distribución previa. La matriz $I_Q$ es la matriz identidad de dimensión $Q \times Q$, por lo que la matriz de covarianza es diagonal:

$$\mathrm{Cov}(w) = \sigma_w^2 I_Q.$$

Para obtener la densidad de esta distribución, se utiliza la fórmula general de la densidad de una distribución gaussiana multivariante. Si un vector aleatorio $w \in \mathbb{R}^Q$ sigue una distribución gaussiana de media $\mu$ y matriz de covarianza $\Sigma$, su densidad es

$$p(w) = \frac{1}{(2\pi)^{Q/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(w-\mu)^T\Sigma^{-1}(w-\mu)\right),$$

donde $|\Sigma|$ representa el determinante de la matriz de covarianza y $\Sigma^{-1}$ su matriz inversa.

En el modelo considerado, la media es $\mu = 0$ y la matriz de covarianza es $\Sigma = \sigma_w^2 I_Q$. Para sustituir estos valores en la fórmula general, se calculan el determinante y la inversa de la matriz de covarianza.

En primer lugar, el determinante de una matriz identidad de dimensión $Q$, multiplicada por un escalar $\sigma_w^2$, es el producto de ese escalar elevado a la dimensión de la matriz:

$$|\Sigma| = |\sigma_w^2 I_Q| = (\sigma_w^2)^Q.$$

Por tanto,

$$|\Sigma|^{1/2} = \left((\sigma_w^2)^Q\right)^{1/2} = (\sigma_w^2)^{Q/2},$$

donde se supone que $\sigma_w^2 > 0$.

En segundo lugar, la inversa de una matriz identidad multiplicada por un escalar distinto de cero se obtiene tomando el inverso del escalar:

$$\Sigma^{-1} = (\sigma_w^2 I_Q)^{-1} = \frac{1}{\sigma_w^2} I_Q.$$

Ahora se sustituyen estos resultados y $\mu = 0$ en la densidad gaussiana multivariante:

$$p(w) = \frac{1}{(2\pi)^{Q/2}(\sigma_w^2)^{Q/2}} \exp\left(-\frac{1}{2} w^T \left(\frac{1}{\sigma_w^2} I_Q\right) w\right).$$

El factor constante del denominador puede escribirse como una potencia:

$$\frac{1}{(2\pi)^{Q/2}(\sigma_w^2)^{Q/2}} = (2\pi\sigma_w^2)^{-Q/2}.$$

Asimismo, al utilizar la propiedad del producto matricial $w^T I_Q w = w^T w$, el exponente se simplifica a

$$-\frac{1}{2} w^T \left(\frac{1}{\sigma_w^2} I_Q\right) w = -\frac{w^T w}{2\sigma_w^2}.$$

Por tanto, la distribución previa de los parámetros queda expresada mediante la densidad

$$\boxed{p(w) = (2\pi\sigma_w^2)^{-Q/2} \exp\left(-\frac{w^T w}{2\sigma_w^2}\right)}$$

Como $w^T w = \|w\|_2^2$, esta densidad también puede escribirse como

$$p(w) = (2\pi\sigma_w^2)^{-Q/2} \exp\left(-\frac{\|w\|_2^2}{2\sigma_w^2}\right).$$

Esta forma muestra que la densidad previa depende de la magnitud del vector de parámetros. Los valores de $w$ cercanos al vector cero reciben mayor densidad previa, mientras que los valores con mayor norma reciben menor densidad. La varianza $\sigma_w^2$ controla

la dispersión de la distribución: una varianza pequeña concentra la distribución alrededor de cero y una varianza grande permite una mayor dispersión de los parámetros.

### 4. Construcción de la distribución posterior

Una vez obtenidas la verosimilitud y la distribución previa, ambas se sustituyen en la expresión proporcional del teorema de Bayes:

$$p(w \mid t, X) \propto p(t \mid X, w)p(w).$$

La verosimilitud obtenida en el apartado anterior es

$$p(t \mid X, w) = (2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2}\right),$$

mientras que la distribución previa derivada en el apartado anterior es

$$p(w) = (2\pi\sigma_w^2)^{-Q/2} \exp\left(-\frac{w^T w}{2\sigma_w^2}\right).$$

Al sustituir estas dos expresiones en la distribución posterior proporcional, se obtiene

$$\begin{aligned} p(w \mid t, X) \propto & \left[(2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2}\right)\right] \\ & \times \left[(2\pi\sigma_w^2)^{-Q/2} \exp\left(-\frac{w^T w}{2\sigma_w^2}\right)\right]. \end{aligned}$$

Esta sustitución se justifica directamente por la regla de Bayes: la distribución posterior es proporcional al producto de la verosimilitud y la distribución previa. Los dos factores entre corchetes corresponden, respectivamente, a la densidad de los datos condicionada a los parámetros y a la densidad previa de los parámetros.

Los factores $(2\pi\sigma_\eta^2)^{-N/2}$ y $(2\pi\sigma_w^2)^{-Q/2}$ no dependen de $w$, por lo que pueden agruparse en una constante multiplicativa. Además, se utiliza la propiedad de las exponenciales

$$e^a e^b = e^{a+b},$$

que permite transformar el producto de las dos exponenciales en una única exponencial cuya potencia es la suma de los exponentes. Así, la distribución posterior puede escribirse como

$$\boxed{p(w \mid t, X) \propto \exp\left(-\frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2} - \frac{w^T w}{2\sigma_w^2}\right)}$$

Esta expresión conserva la misma posición del máximo que la distribución posterior completa, ya que los factores omitidos son constantes positivas independientes de $w$.

### 5. Transformación del problema de maximización en un problema de minimización

El estimador MAP se define como

$$\hat{w}_{\text{MAP}} = \arg\max_w p(w \mid t, X).$$

Al sustituir la distribución posterior proporcional obtenida, se tiene

$$\hat{w}_{\text{MAP}} = \arg\max_{w} \exp\left(-\frac{\|t-\Phi w\|_2^2}{2\sigma_\eta^2} - \frac{w^T w}{2\sigma_w^2}\right).$$

Para simplificar esta optimización se emplea una propiedad de la función exponencial: es estrictamente creciente. Por consiguiente, si dos valores de $w$ producen exponentes diferentes, el que produzca el exponente mayor también producirá el valor mayor de la exponencial. Por tanto, maximizar la exponencial equivale a maximizar su exponente:

$$\hat{w}_{\text{MAP}} = \arg\max_{w} \left[-\frac{\|t-\Phi w\|_2^2}{2\sigma_\eta^2} - \frac{w^T w}{2\sigma_w^2}\right].$$

A continuación, se multiplica la función objetivo por $-1$. Esta operación transforma la maximización en una minimización, pues el valor que maximiza una función es el que minimiza su negativo:

$$\hat{w}_{\text{MAP}} = \arg\min_{w} \left[\frac{\|t-\Phi w\|_2^2}{2\sigma_\eta^2} + \frac{w^T w}{2\sigma_w^2}\right].$$

Los dos términos de esta expresión están divididos por constantes positivas. Por ello, se puede multiplicar toda la función objetivo por $2\sigma_\eta^2$, sin modificar el vector $w$ que la minimiza. Al efectuar esta operación, se obtiene

$$\hat{w}_{\text{MAP}} = \arg\min_{w} \left[\|t-\Phi w\|_2^2 + \frac{\sigma_\eta^2}{\sigma_w^2} w^T w\right].$$

Finalmente, al utilizar la identidad $w^T w = \|w\|_2^2$, la función objetivo puede escribirse como

$$\boxed{J(w) = \|t-\Phi w\|_2^2 + \frac{\sigma_\eta^2}{\sigma_w^2}\|w\|_2^2}$$

Esta expresión tiene la estructura de una función de mínimos cuadrados regularizados. El primer término mide el error cuadrático entre los valores objetivo observados y las predicciones del modelo; el segundo penaliza la magnitud de los parámetros. La penalización se origina en la distribución previa gaussiana: los parámetros con mayor magnitud tienen menor densidad previa y, por tanto, reciben una penalización mayor en el problema de minimización equivalente.

Definiendo el parámetro de regularización como

$$\boxed{\lambda = \frac{\sigma_\eta^2}{\sigma_w^2}}$$

la función objetivo se simplifica a

$$J(w) = \|t-\Phi w\|_2^2 + \lambda\|w\|_2^2.$$

Esta relación establece que la intensidad de la regularización no se introduce arbitrariamente, sino que se deriva de las varianzas del modelo probabilístico. Una varianza del ruido $\sigma_\eta^2$ mayor incrementa la regularización relativa, mientras que una varianza previa $\sigma_w^2$ mayor la reduce.

## 6. Derivación de la solución cerrada del estimador MAP

Para determinar el valor de $w$ que minimiza la función objetivo, se utiliza el cálculo diferencial matricial. La función a minimizar es

$$J(w) = \|t - \Phi w\|_2^2 + \lambda \|w\|_2^2.$$

Primero, se expresan las normas al cuadrado mediante productos matriciales:

$$J(w) = (t - \Phi w)^T (t - \Phi w) + \lambda w^T w.$$

Al desarrollar el primer producto matricial, se obtiene

$$J(w) = t^T t - t^T \Phi w - w^T \Phi^T t + w^T \Phi^T \Phi w + \lambda w^T w.$$

Como $t^T \Phi w$ es un escalar y $w^T \Phi^T t$ es su transpuesto, ambos tienen el mismo valor. Por ello, la expresión puede simplificarse a

$$J(w) = t^T t - 2w^T \Phi^T t + w^T \Phi^T \Phi w + \lambda w^T w.$$

Para encontrar el mínimo, se calcula el gradiente de la función respecto al vector de parámetros $w$. Se utilizan las siguientes reglas de derivación matricial: la derivada de un término constante respecto a $w$ es cero; el gradiente de un término lineal $w^T a$, donde $a$ es constante, es $a$; y el gradiente de una forma cuadrática $w^T A w$, cuando $A$ es simétrica, es $2Aw$.

Aplicando estas reglas, el gradiente de la función objetivo es

$$\nabla_w J(w) = -2\Phi^T t + 2\Phi^T \Phi w + 2\lambda w.$$

La condición necesaria de primer orden para obtener el mínimo consiste en igualar el gradiente a cero:

$$-2\Phi^T t + 2\Phi^T \Phi w + 2\lambda w = 0.$$

Dividiendo ambos lados entre dos y agrupando los términos que contienen $w$, se obtiene

$$\Phi^T \Phi w + \lambda w = \Phi^T t,$$

o, de forma equivalente,

$$(\Phi^T \Phi + \lambda I_Q) w = \Phi^T t.$$

La matriz identidad $I_Q$ permite expresar el término $\lambda w$ como un producto matricial, dado que $I_Q w = w$. Si $\lambda > 0$, la matriz $\Phi^T \Phi + \lambda I_Q$ es definida positiva. En efecto, para cualquier vector no nulo $z \in \mathbb{R}^Q$,

$$\begin{aligned} z^T (\Phi^T \Phi + \lambda I_Q) z &= z^T \Phi^T \Phi z + \lambda z^T z \\ &= \|\Phi z\|_2^2 + \lambda \|z\|_2^2 \\ &> 0. \end{aligned}$$

La desigualdad se cumple porque $\|\Phi z\|_2^2 \geq 0$, $\lambda > 0$ y $\|z\|_2^2 > 0$ para todo vector no nulo. Por tanto, la matriz es invertible y la ecuación puede resolverse multiplicando ambos lados por su inversa.

Así se obtiene la solución cerrada del estimador MAP:

$$\boxed{\hat{w}_{\text{MAP}} = (\Phi^T\Phi + \lambda I_Q)^{-1}\Phi^T t}$$

Al sustituir $\lambda = \sigma_\eta^2/\sigma_w^2$, se obtiene la expresión final en función de los parámetros probabilísticos del modelo:

$$\boxed{\hat{w}_{\text{MAP}} = \left(\Phi^T\Phi + \frac{\sigma_\eta^2}{\sigma_w^2} I_Q\right)^{-1} \Phi^T t}$$

Esta solución muestra que el estimador MAP coincide con el estimador de mínimos cuadrados regularizados cuando se utiliza una distribución previa gaussiana de media cero y una verosimilitud gaussiana. Además, al ser $\lambda > 0$, la matriz de la ecuación normal es definida positiva y la solución es única, incluso cuando las columnas de la matriz de diseño no son linealmente independientes.

## 1.5 Implementación y análisis.

Listing 1: Enfoques Anteriores en Python

```python
import numpy as np

np.random.seed(42)

# Generar datos
N = 300
P = 5
Q = 20

X = np.random.randn(N, P)

# Construir la matriz Phi
cuadrados = X**2
productos_cruzados = []

for i in range(P):
    for j in range(i + 1, P):
        productos_cruzados.append(
            (X[:, i] * X[:, j]).reshape(-1, 1)
        )

Phi = np.hstack([X, cuadrados] + productos_cruzados)

# Modelo verdadero
w_star = np.random.randn(Q)

sigma_eta = 0.5
eta = np.random.normal(0, sigma_eta, N)
t = Phi @ w_star + eta

# Dividir entrenamiento y prueba
indices = np.arange(N)
np.random.shuffle(indices)

N_train = int(0.8 * N)
train_idx = indices[:N_train]
```

```python
test_idx = indices[N_train:]

Phi_train = Phi[train_idx]
t_train = t[train_idx]
Phi_test = Phi[test_idx]
t_test = t[test_idx]

# Matrices comunes
A = Phi_train.T @ Phi_train
b = Phi_train.T @ t_train
I = np.eye(Q)

# OLS
w_ols = np.linalg.solve(A, b)

# Ridge
lambda_reg = 1.0
w_ridge = np.linalg.solve(
    A + lambda_reg * I, b
)

# MLE
w_mle = np.linalg.solve(A, b)

# MAP
sigma_eta2 = sigma_eta**2
sigma_w2 = sigma_eta2 / lambda_reg
ratio_map = sigma_eta2 / sigma_w2

w_map = np.linalg.solve(
    A + ratio_map * I, b
)

# Evaluar estimadores
estimadores = {
    "OLS": w_ols,
    "Ridge": w_ridge,
    "MLE": w_mle,
    "MAP": w_map
}

print("Metodo | MSE train | MSE test | Error parametros")

for nombre, w in estimadores.items():
    mse_train = np.mean(
        (t_train - Phi_train @ w)**2
    )
    mse_test = np.mean(
        (t_test - Phi_test @ w)**2
    )
    error_w = np.linalg.norm(w - w_star)

    print(
        nombre, "|", mse_train,
        "|", mse_test, "|", error_w
    )

# Comparar soluciones
```

```
print(
    "Diferencia OLS-MLE:",
    np.linalg.norm(w_ols - w_mle)
)

print(
    "Diferencia Ridge-MAP:",
    np.linalg.norm(w_ridge - w_map)
)
```

# 2 Espacios RKHS, embeddings de media y discrepancia entre distribuciones.

## 2.1 Definición rigurosa del embedding de media

Sea $\mathcal{X}$ un espacio de entrada y sea $X$ una variable aleatoria que toma valores en ese espacio, con distribución de probabilidad $P_X$. Se considera un kernel simétrico y definido positivo,

$$k : \mathcal{X} \times \mathcal{X} \longrightarrow \mathbb{R},$$

y se denota por $\mathcal{H}_k$ al espacio de Hilbert con núcleo reproductor (RKHS) asociado a dicho kernel.

El objetivo del embedding de media es representar una distribución de probabilidad mediante un elemento de un espacio de funciones. Para construir esta representación, primero se asocia cada posible observación $x \in \mathcal{X}$ con una función determinada por el kernel.

En concreto, para cada $x$, se define la función

$$k(x, \cdot) : \mathcal{X} \longrightarrow \mathbb{R},$$

que toma un valor $z \in \mathcal{X}$ y devuelve $k(x, z)$. Es decir,

$$k(x, \cdot)(z) = k(x, z).$$

El punto en $k(x, \cdot)$ indica que el segundo argumento del kernel queda libre para variar. Por ejemplo, si fijamos $x$, obtenemos una función que podemos evaluar en distintos valores de $z$.

Por la propiedad reproductora del RKHS, cada una de estas funciones pertenece al espacio $\mathcal{H}_k$. De esta manera, cada observación $x$ queda representada por una función $k(x, \cdot)$ dentro de dicho espacio.

A partir de esta idea, se define el embedding de media como la esperanza de esas funciones:

$$\boxed{\mu_k(P_X) = \mathbb{E}_{X \sim P_X}[k(X, \cdot)]}$$

Esta expresión significa que, en lugar de representar únicamente una observación, se consideran los posibles valores que puede tomar $X$ y se calcula el promedio de las funciones que les corresponden, teniendo en cuenta sus probabilidades. El resultado es una función

$\mu_k(P_X)$ que pertenece a $\mathcal{H}_k$, siempre que se cumplan las condiciones necesarias para que esta esperanza exista.

También se utiliza la notación abreviada

$$\mu_X = \mathbb{E}[k(X, \cdot)],$$

cuando la distribución de $X$ está clara por el contexto.

**Cómo se calcula el embedding según la distribución**

La expresión del embedding de media depende de cómo se distribuye la probabilidad entre los valores posibles de $X$. Para entenderlo, conviene distinguir entre el caso discreto y el continuo.

**Caso 1: distribución discreta**

Supongamos que $X$ puede tomar los valores $x_1, x_2, \ldots, x_n$, y que cada valor tiene una probabilidad asociada:

$$P_X(X = x_i) = p_i.$$

Estas probabilidades cumplen

$$p_i \geq 0, \qquad \sum_{i=1}^{n} p_i = 1.$$

Como $X$ solo puede tomar esos valores, la función aleatoria $k(X, \cdot)$ también puede ser una de las funciones

$$k(x_1, \cdot),\ k(x_2, \cdot),\ \ldots,\ k(x_n, \cdot).$$

La esperanza de una variable aleatoria discreta se calcula multiplicando cada valor por su probabilidad y sumando los resultados. Aplicamos exactamente la misma idea a las funciones $k(x_i, \cdot)$: multiplicamos cada función por la probabilidad de la observación correspondiente y después sumamos.

Por tanto, el embedding de media es

$$\boxed{\mu_k(P_X) = \sum_{i=1}^{n} p_i\, k(x_i, \cdot)}$$

Para verlo de forma más concreta, si $X$ puede tomar tres valores $x_1, x_2, x_3$, el embedding es

$$\mu_k(P_X) = p_1 k(x_1, \cdot) + p_2 k(x_2, \cdot) + p_3 k(x_3, \cdot).$$

Cada función contribuye al resultado según la probabilidad de su observación. Si un valor tiene una probabilidad alta, su función tiene más peso en la suma; si su probabilidad es pequeña, tiene menos peso. Las probabilidades suman uno, por lo que esta operación constituye una combinación ponderada de las funciones.

**Caso 2: distribución continua**

Si $X$ sigue una distribución continua, no basta con sumar las funciones asociadas a unos pocos valores, ya que la variable puede tomar valores en un conjunto continuo. En este caso, la esperanza se expresa mediante una integral.

La fórmula es

$$\boxed{\mu_k(P_X) = \int_{\mathcal{X}} k(x, \cdot)\, dP_X(x)}$$

El símbolo $dP_X(x)$ indica que la integración se realiza teniendo en cuenta la distribución de probabilidad de $X$. En otras palabras, no todos los valores tienen necesariamente la misma contribución: la integral acumula las funciones $k(x, \cdot)$ de acuerdo con cómo se distribuye la probabilidad sobre el espacio $\mathcal{X}$.

Esta integral es la versión continua de la suma ponderada del caso discreto. En el caso discreto, se multiplica cada función por una probabilidad y se suman los términos. En el caso continuo, se integran las funciones respecto a la medida de probabilidad.

Si la distribución de $X$ tiene una función de densidad $p_X(x)$, la probabilidad se puede expresar mediante esa densidad. En tal caso,

$$dP_X(x) = p_X(x)\, dx,$$

y la fórmula anterior se escribe como

$$\boxed{\mu_k(P_X) = \int_{\mathcal{X}} k(x, \cdot)\, p_X(x)\, dx}$$

Aquí, $p_X(x)$ es la densidad de probabilidad y $dx$ representa el elemento de integración del espacio de entrada. La densidad determina cuánto contribuye cada zona del espacio al promedio: las regiones con mayor densidad de probabilidad tienen mayor peso en la integral.

Es importante distinguir que la fórmula con densidad solo se utiliza cuando existe una densidad respecto a la medida de referencia considerada. La expresión $\int_{\mathcal{X}} k(x, \cdot)\, dP_X(x)$ es más general y no requiere que la distribución tenga una densidad.

**Condiciones para que el embedding exista**

Para que la esperanza de las funciones $k(X, \cdot)$ esté bien definida como una integral de funciones con valores en el espacio de Hilbert, se requieren condiciones de medibilidad e integrabilidad.

Una condición suficiente habitual es que la función $x \mapsto k(x, \cdot)$ sea fuertemente medible y que

$$\mathbb{E}\left[\sqrt{k(X, X)}\right] < \infty.$$

Esta condición controla el tamaño de las funciones asociadas a las observaciones. En efecto, en el RKHS se cumple la propiedad

$$\|k(x, \cdot)\|_{\mathcal{H}_k} = \sqrt{k(x, x)}.$$

Por tanto, la condición anterior equivale a exigir que la norma de la función aleatoria $k(X, \cdot)$ tenga esperanza finita. Bajo estas condiciones, el embedding de media existe como elemento de $\mathcal{H}_k$.

“‘latex

## 2.2 Pertenencia al RKHS e interpretación geométrica

Sea $X$ una variable aleatoria definida sobre un espacio $\mathcal{X}$, con distribución de probabilidad $P_X$. Consideremos un kernel simétrico definido positivo $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ y el espacio

de Hilbert con núcleo reproductor asociado, denotado por $\mathcal{H}_k$. Como se estableció en el apartado 2.1, el embedding de media de la distribución $P_X$ se define mediante

$$\mu_X = \mathbb{E}[k(X, \cdot)].$$

Esta expresión representa la esperanza de una función aleatoria cuyos valores pertenecen a $\mathcal{H}_k$. Para justificar que el embedding está bien definido y pertenece a dicho espacio, es necesario introducir la propiedad reproductora del kernel, establecer las condiciones de existencia de la esperanza en un espacio de funciones y relacionar el embedding con los productos internos del RKHS.

**Propiedad reproductora del kernel**

Un espacio de Hilbert es un espacio vectorial equipado con un producto interno que permite definir la norma y la distancia entre sus elementos. En un RKHS, los elementos son funciones $f : \mathcal{X} \to \mathbb{R}$, y el producto interno se denota por $\langle f, g \rangle_{\mathcal{H}_k}$.

La propiedad fundamental de un espacio de Hilbert con núcleo reproductor establece que, para cada $x \in \mathcal{X}$, la función $k(x, \cdot)$ pertenece a $\mathcal{H}_k$ y satisface

$$\boxed{f(x) = \langle f, k(x, \cdot) \rangle_{\mathcal{H}_k}, \qquad f \in \mathcal{H}_k.}$$

Esta igualdad recibe el nombre de propiedad reproductora porque permite recuperar el valor de una función $f$ en un punto $x$ mediante el producto interno de $f$ con la función $k(x, \cdot)$. Por tanto, la evaluación de una función en el espacio original queda expresada mediante una operación geométrica en el RKHS.

En particular, tomando $f = k(x, \cdot)$, la propiedad reproductora implica que

$$\langle k(x, \cdot), k(x, \cdot) \rangle_{\mathcal{H}_k} = k(x, x).$$

La norma de un elemento de un espacio de Hilbert se define como la raíz cuadrada de su producto interno consigo mismo. En consecuencia,

$$\boxed{\|k(x, \cdot)\|_{\mathcal{H}_k} = \sqrt{k(x, x)}.}$$

Esta igualdad permite expresar la norma de la función asociada a cada observación directamente en términos del kernel, lo cual resulta esencial para justificar la existencia del embedding de media.

**Esperanza de funciones e integral de Bochner**

En la esperanza de una variable aleatoria escalar, los valores posibles son números reales y su promedio pertenece a $\mathbb{R}$. En cambio, en la expresión $\mathbb{E}[k(X, \cdot)]$, la variable aleatoria toma valores en un espacio de funciones. Por esta razón, la esperanza debe definirse de manera que el resultado pertenezca al mismo espacio $\mathcal{H}_k$.

La integral de Bochner generaliza la integral de funciones escalares a funciones cuyos valores pertenecen a un espacio de Banach, es decir, un espacio vectorial normado y completo. Como todo espacio de Hilbert es también un espacio de Banach, esta integral permite definir rigurosamente la esperanza de una variable aleatoria con valores en $\mathcal{H}_k$.

La construcción conserva la interpretación habitual de una esperanza como promedio ponderado. Si una función aleatoria $Z$ toma un número finito de valores $h_1, \ldots, h_r \in \mathcal{H}_k$, asociados a eventos disjuntos $A_1, \ldots, A_r$, su integral de Bochner se expresa como

$$\int Z \, dP_X = \sum_{j=1}^{r} P_X(A_j) h_j.$$

En este caso, el resultado es una combinación lineal de elementos de $\mathcal{H}_k$ ponderados por sus probabilidades y, por tanto, también pertenece al espacio. Para funciones que toman infinitos valores, la integral se construye mediante aproximaciones por funciones simples, siempre que se satisfagan las condiciones de medibilidad e integrabilidad correspondientes.

En el caso del embedding de media, la función aleatoria considerada es

$$Z(X) = k(X, \cdot),$$

y su esperanza se define mediante la integral de Bochner:

$$\boxed{\mu_X = \int_{\mathcal{X}} k(x, \cdot)\, dP_X(x).}$$

La notación $\mathbb{E}[k(X, \cdot)]$ representa esta misma integral. Su resultado será un elemento de $\mathcal{H}_k$ si se cumplen las condiciones que garantizan la existencia de la integral.

**Condiciones de existencia de la integral de Bochner**

Para que una función con valores en un espacio de Hilbert sea integrable en el sentido de Bochner, se requiere que sea medible en el sentido apropiado y que su norma tenga esperanza finita. En el caso del embedding de media, una condición suficiente habitual consiste en que el kernel sea medible y se cumpla

$$\boxed{\mathbb{E}[\sqrt{k(X, X)}] < \infty.}$$

La procedencia de esta condición se obtiene a partir de la norma de la función aleatoria. En efecto, por la propiedad reproductora,

$$\begin{aligned} \|Z(X)\|_{\mathcal{H}_k} &= \|k(X, \cdot)\|_{\mathcal{H}_k} \\ &= \sqrt{k(X, X)}. \end{aligned}$$

El criterio de integrabilidad de Bochner exige que

$$\mathbb{E}[\|Z(X)\|_{\mathcal{H}_k}] < \infty.$$

Al sustituir la expresión de la norma, resulta directamente

$$\mathbb{E}[\sqrt{k(X, X)}] < \infty.$$

Por tanto, esta condición no es arbitraria: se deriva del requisito de que la norma de la función aleatoria sea integrable. La medibilidad del kernel garantiza, bajo las condiciones habituales del espacio de entrada y del RKHS, la medibilidad necesaria de la función $x \mapsto k(x, \cdot)$.

Cuando se cumplen estas condiciones, la integral de Bochner existe. Como el integrando toma valores en $\mathcal{H}_k$, su integral también pertenece a dicho espacio. Se concluye así que

$$\boxed{\mu_X \in \mathcal{H}_k.}$$

La condición de integrabilidad indicada es suficiente, aunque no es necesaria en todos los casos posibles. Su importancia radica en que permite garantizar la existencia del embedding mediante una condición verificable a partir del kernel y de la distribución de $X$.

**Caracterización del embedding mediante el producto interno**

Una vez establecida la existencia de $\mu_X$, la propiedad reproductora permite obtener una identidad que caracteriza su relación con las funciones del RKHS. Sea $f \in \mathcal{H}_k$. Por definición del embedding,

$$\langle f, \mu_X \rangle_{\mathcal{H}_k} = \langle f, \mathbb{E}[k(X, \cdot)] \rangle_{\mathcal{H}_k} .$$

El producto interno con un elemento fijo $f$ es una aplicación lineal y continua. Por la propiedad de la integral de Bochner respecto a aplicaciones lineales continuas, el producto interno puede intercambiarse con la esperanza:

$$\langle f, \mathbb{E}[k(X, \cdot)] \rangle_{\mathcal{H}_k} = \mathbb{E} \left[ \langle f, k(X, \cdot) \rangle_{\mathcal{H}_k} \right] .$$

A continuación, aplicamos la propiedad reproductora a cada realización de $X$. Para cualquier $x \in \mathcal{X}$, se tiene

$$\langle f, k(x, \cdot) \rangle_{\mathcal{H}_k} = f(x).$$

Por consiguiente,

$$\langle f, k(X, \cdot) \rangle_{\mathcal{H}_k} = f(X),$$

y la igualdad anterior se transforma en

$$\mathbb{E} \left[ \langle f, k(X, \cdot) \rangle_{\mathcal{H}_k} \right] = \mathbb{E}[f(X)].$$

Combinando estas relaciones, obtenemos

$$\boxed{\langle f, \mu_X \rangle_{\mathcal{H}_k} = \mathbb{E}[f(X)], \qquad f \in \mathcal{H}_k.}$$

Esta identidad establece que el producto interno de cualquier función $f$ del RKHS con el embedding de media devuelve la esperanza de $f(X)$. Su validez se apoya en dos resultados previamente justificados: la existencia de la integral de Bochner y la propiedad reproductora del kernel.

Es importante distinguir ambas afirmaciones. La pertenencia $\mu_X \in \mathcal{H}_k$ queda garantizada por la existencia de la integral de Bochner bajo las condiciones de medibilidad e integrabilidad indicadas. La identidad del producto interno describe, a su vez, cómo el embedding representa los promedios de las funciones pertenecientes al RKHS. No es la identidad por sí sola la que garantiza la existencia del embedding; esta se establece previamente mediante la integral.

**Interpretación geométrica**

El espacio original $\mathcal{X}$ contiene las observaciones, mientras que el RKHS $\mathcal{H}_k$ es un espacio de funciones en el que cada observación $x$ se representa mediante $k(x, \cdot)$. El embedding de media corresponde al promedio de esas representaciones respecto a la distribución de probabilidad:

$$\mu_X = \mathbb{E}[k(X, \cdot)].$$

Geométricamente, $\mu_X$ es un elemento del RKHS que resume las representaciones de las observaciones, ponderadas según la distribución de $X$. Si la distribución es discreta, el promedio es una suma ponderada de funciones; si es continua, se obtiene mediante una integral.

La identidad

$$\langle f, \mu_X \rangle_{\mathcal{H}_k} = \mathbb{E}[f(X)]$$

permite interpretar con mayor precisión este representante: sus productos internos con las funciones del RKHS recuperan las esperanzas de dichas funciones bajo $P_X$. Así, el embedding traslada información sobre una distribución del espacio original a una representación geométrica en el RKHS.

La capacidad de esta representación para distinguir distribuciones depende del kernel. Si $k$ es un kernel característico, la aplicación $P_X \mapsto \mu_X$ es inyectiva, de modo que dos distribuciones tienen el mismo embedding si y solo si son iguales. Para kernels que no son característicos, distribuciones diferentes pueden compartir el mismo embedding.

Un kernel $k$ se denomina característico cuando permite distinguir distribuciones de probabilidad diferentes mediante sus embeddings de media.

Matemáticamente, sea $P_X$ una distribución y sea su embedding de media

$$\mu_k(P_X) = \mathbb{E}_{X \sim P_X}[k(X, \cdot)].$$

El kernel es característico si la aplicación que asigna a cada distribución su embedding de media es inyectiva, es decir, si se cumple que

$$\boxed{\mu_k(P_X) = \mu_k(P_Y) \iff P_X = P_Y.}$$

Esto significa que dos distribuciones tienen el mismo embedding si y solo si son la misma distribución.

Por el contrario, si un kernel no es característico, pueden existir dos distribuciones distintas $P_X \neq P_Y$ cuyos embeddings de media sean iguales. En ese caso, el embedding no permite distinguir esas distribuciones.

**Ejemplo: kernel constante**

Consideremos el kernel constante $k(x, y) = 1$. Para cualquier distribución $P_X$,

$$\mu_k(P_X) = \mathbb{E}[1] = 1.$$

Por tanto, todas las distribuciones tienen el mismo embedding, independientemente de cómo se distribuyan sus probabilidades. Este kernel no es característico, porque no permite distinguir ninguna distribución de otra.

En cambio, el kernel gaussiano habitual,

$$k(x, y) = \exp\left(-\frac{\|x - y\|^2}{2\sigma^2}\right), \qquad \sigma > 0,$$

es característico sobre $\mathbb{R}^d$. En consecuencia, distribuciones de probabilidad diferentes sobre ese espacio tienen embeddings de media diferentes.

“‘latex

## 2.3 Discrepancia máxima de medias (MMD)

**Definición y propósito de la MMD**

Sean $X \sim P_X$ y $Y \sim P_Y$ dos variables aleatorias independientes, definidas sobre el mismo espacio $\mathcal{X}$. Las distribuciones $P_X$ y $P_Y$ describen el comportamiento probabilístico de ambas variables.

El objetivo de la discrepancia máxima de medias (Maximum Mean Discrepancy, MMD) es medir qué tan diferentes son dos distribuciones de probabilidad. Para ello, en lugar de comparar directamente sus funciones de densidad o sus probabilidades, se representan las distribuciones mediante sus embeddings de media en un espacio de Hilbert con núcleo reproductor (RKHS).

Sea $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ un kernel simétrico definido positivo y sea $\mathcal{H}_k$ el RKHS asociado. Los embeddings poblacionales se definen como

$$\mu_X = \mathbb{E}[k(X, \cdot)], \qquad \mu_Y = \mathbb{E}[k(Y, \cdot)].$$

Cada embedding es un elemento de $\mathcal{H}_k$ que representa una distribución. La MMD cuadrática se define como la distancia al cuadrado entre estos dos elementos:

$$\boxed{\mathrm{MMD}^2(P_X, P_Y) = \|\mu_X - \mu_Y\|^2_{\mathcal{H}_k}}$$

Si la MMD es pequeña, los embeddings están próximos en el RKHS; si es grande, están más alejados. Que esta distancia permita distinguir siempre distribuciones diferentes depende del kernel: si $k$ es característico, la MMD es cero si y solo si $P_X = P_Y$.

**Desarrollo de la expresión poblacional**

Para entender de dónde proviene la fórmula de la MMD, primero se utiliza una propiedad básica de los espacios con producto interno. La norma de un elemento $f \in \mathcal{H}_k$ satisface

$$\|f\|^2_{\mathcal{H}_k} = \langle f, f \rangle_{\mathcal{H}_k}.$$

Aplicando esta propiedad a la definición de MMD,

$$\mathrm{MMD}^2(P_X, P_Y) = \langle \mu_X - \mu_Y, \mu_X - \mu_Y \rangle_{\mathcal{H}_k}.$$

El producto interno es bilineal, por lo que se distribuye sobre la resta en cada argumento:

$$\begin{aligned}\langle \mu_X - \mu_Y, \mu_X - \mu_Y \rangle_{\mathcal{H}_k} = {} & \langle \mu_X, \mu_X \rangle_{\mathcal{H}_k} \\ & - \langle \mu_X, \mu_Y \rangle_{\mathcal{H}_k} \\ & - \langle \mu_Y, \mu_X \rangle_{\mathcal{H}_k} \\ & + \langle \mu_Y, \mu_Y \rangle_{\mathcal{H}_k}.\end{aligned}$$

Como el producto interno real es simétrico,

$$\langle \mu_Y, \mu_X \rangle_{\mathcal{H}_k} = \langle \mu_X, \mu_Y \rangle_{\mathcal{H}_k},$$

los dos términos cruzados son iguales. Por eso se combinan y se obtiene

$$\boxed{\begin{aligned}\mathrm{MMD}^2(P_X, P_Y) = {} & \langle \mu_X, \mu_X \rangle_{\mathcal{H}_k} \\ & + \langle \mu_Y, \mu_Y \rangle_{\mathcal{H}_k} \\ & - 2\langle \mu_X, \mu_Y \rangle_{\mathcal{H}_k}.\end{aligned}}$$

Esta igualdad es una aplicación de la identidad algebraica $(a - b)^2 = a^2 + b^2 - 2ab$, generalizada a elementos de un espacio con producto interno.

### 2.3.1. Cómo se transforman los productos internos en esperanzas del kernel

Recordemos que

$$\mu_X = \mathbb{E}[k(X, \cdot)].$$

Esta esperanza no es una media de números escalares, sino una esperanza de funciones que pertenecen al RKHS. Bajo las condiciones de integrabilidad necesarias, el producto interno puede intercambiarse con las esperanzas de Bochner.

Para calcular el primer término, introducimos $X'$, una copia independiente de $X$, con la misma distribución $P_X$. Entonces,

$$\begin{aligned}\langle \mu_X, \mu_X \rangle_{\mathcal{H}_k} &= \langle \mathbb{E}_X[k(X, \cdot)], \mathbb{E}_{X'}[k(X', \cdot)] \rangle_{\mathcal{H}_k} \\ &= \mathbb{E}_{X,X'} \left[ \langle k(X, \cdot), k(X', \cdot) \rangle_{\mathcal{H}_k} \right].\end{aligned}$$

aparece $X'$ aparece porque las dos apariciones de $\mu_X$ representan dos factores promediados respecto de la misma distribución. Para expresar ese producto como una sola esperanza conjunta, se utilizan dos extracciones independientes de $P_X$. No significa que $X'$ tenga una distribución distinta de $X$.

Ahora aplicamos la propiedad reproductora del RKHS:

$$\langle k(x, \cdot), k(x', \cdot) \rangle_{\mathcal{H}_k} = k(x, x').$$

Esta propiedad convierte el producto interno entre dos funciones del RKHS en una evaluación del kernel entre los puntos correspondientes. Por tanto,

$$\boxed{\langle \mu_X, \mu_X \rangle_{\mathcal{H}_k} = \mathbb{E}_{X,X'}[k(X, X')]}$$

De manera equivalente, para $Y'$, una copia independiente de $Y$,

$$\boxed{\langle \mu_Y, \mu_Y \rangle_{\mathcal{H}_k} = \mathbb{E}_{Y,Y'}[k(Y, Y')]}$$

Para el término cruzado, se utilizan $X$ y $Y$, que son independientes por hipótesis:

$$\begin{aligned}\langle \mu_X, \mu_Y \rangle_{\mathcal{H}_k} &= \langle \mathbb{E}_X[k(X, \cdot)], \mathbb{E}_Y[k(Y, \cdot)] \rangle_{\mathcal{H}_k} \\ &= \mathbb{E}_{X,Y} \left[ \langle k(X, \cdot), k(Y, \cdot) \rangle_{\mathcal{H}_k} \right] \\ &= \mathbb{E}_{X,Y}[k(X, Y)].\end{aligned}$$

Al sustituir los tres resultados en la definición de la MMD, se obtiene su formulación poblacional:

$$\boxed{\begin{aligned}\mathrm{MMD}^2(P_X, P_Y) = \mathbb{E}_{X,X'}[k(X, X')] \\ + \mathbb{E}_{Y,Y'}[k(Y, Y')] \\ - 2\mathbb{E}_{X,Y}[k(X, Y)].\end{aligned}}$$

Esta expresión depende de las distribuciones completas $P_X$ y $P_Y$. En una aplicación real, normalmente no se conocen esas distribuciones y solo se dispone de muestras. Por eso se construye un estimador empírico.

**Del embedding poblacional al embedding empírico**

La distinción entre esperanza y media muestral es fundamental.

La esperanza $\mathbb{E}[X]$ es una cantidad poblacional: se calcula a partir de la distribución de la variable aleatoria. En cambio, si se observan $n$ realizaciones $x_1, \ldots, x_n$, la media muestral es

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

En general, la media muestral no es idéntica a la esperanza poblacional para una muestra finita. Sin embargo, si las observaciones son i.i.d. y la esperanza existe, la media muestral es un estimador insesgado de la esperanza:

$$\begin{aligned} \mathbb{E}[\bar{X}] &= \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^{n} X_i\right] \\ &= \frac{1}{n} \sum_{i=1}^{n} \mathbb{E}[X_i] \\ &= \frac{1}{n} \cdot n\, \mathbb{E}[X] \\ &= \mathbb{E}[X]. \end{aligned}$$

Aquí, $\mathbb{E}[\bar{X}]$ es la esperanza de la media muestral considerada como variable aleatoria; no afirma que cada media muestral observada sea exactamente igual a $\mathbb{E}[X]$.

El mismo principio se aplica a los embeddings, con la diferencia de que estos son elementos del RKHS y no números escalares. El embedding poblacional de $X$ es

$$\mu_X = \mathbb{E}[k(X, \cdot)].$$

Dadas las observaciones $x_1, \ldots, x_n$, se estima mediante la media de las funciones del RKHS asociadas a esas observaciones:

$$\boxed{\widehat{\mu}_X = \frac{1}{n} \sum_{i=1}^{n} k(x_i, \cdot)}$$

De manera análoga, para las observaciones $y_1, \ldots, y_m$,

$$\boxed{\widehat{\mu}_Y = \frac{1}{m} \sum_{j=1}^{m} k(y_j, \cdot)}$$

Por tanto, la operación que se realiza es análoga a sustituir una esperanza poblacional por una media muestral. La diferencia es que aquí se promedian funciones pertenecientes a $\mathcal{H}_k$. Bajo las condiciones de integrabilidad, los embeddings empíricos son estimadores insesgados de los embeddings poblacionales:

$$\mathbb{E}[\widehat{\mu}_X] = \mu_X, \qquad \mathbb{E}[\widehat{\mu}_Y] = \mu_Y.$$

Estas igualdades se refieren a la esperanza de los elementos aleatorios del RKHS, no a la igualdad exacta entre un embedding empírico particular y el embedding poblacional.

**Construcción de la MMD empírica**

Una vez obtenidos los embeddings empíricos, se calcula la distancia cuadrática entre ellos:

$$\boxed{\widehat{\mathrm{MMD}}_b^2 = \|\widehat{\mu}_X - \widehat{\mu}_Y\|_{\mathcal{H}_k}^2}$$

El subíndice $b$ identifica la versión sesgada del estimador. Desarrollando la norma con la misma identidad algebraica usada para la MMD poblacional,

$$\begin{aligned}\widehat{\mathrm{MMD}}_b^2 = &\langle \widehat{\mu}_X, \widehat{\mu}_X \rangle_{\mathcal{H}_k} \\ &+ \langle \widehat{\mu}_Y, \widehat{\mu}_Y \rangle_{\mathcal{H}_k} \\ &- 2\langle \widehat{\mu}_X, \widehat{\mu}_Y \rangle_{\mathcal{H}_k}.\end{aligned}$$

Esta expresión se parece a la poblacional, pero ahora los embeddings se calculan a partir de las observaciones disponibles.

Para el primer producto interno, sustituimos la definición de $\widehat{\mu}_X$:

$$\begin{aligned}\langle \widehat{\mu}_X, \widehat{\mu}_X \rangle_{\mathcal{H}_k} &= \left\langle \frac{1}{n}\sum_{i=1}^{n} k(x_i, \cdot), \frac{1}{n}\sum_{i'=1}^{n} k(x_{i'}, \cdot) \right\rangle_{\mathcal{H}_k} \\ &= \frac{1}{n^2}\sum_{i=1}^{n}\sum_{i'=1}^{n} \langle k(x_i, \cdot), k(x_{i'}, \cdot) \rangle_{\mathcal{H}_k} \\ &= \frac{1}{n^2}\sum_{i=1}^{n}\sum_{i'=1}^{n} k(x_i, x_{i'}).\end{aligned}$$

La segunda igualdad se obtiene por la bilinealidad del producto interno; la tercera, por la propiedad reproductora. El factor $1/n^2$ aparece porque se multiplica $1/n$ por $1/n$.

Repitiendo el desarrollo para $Y$,

$$\langle \widehat{\mu}_Y, \widehat{\mu}_Y \rangle_{\mathcal{H}_k} = \frac{1}{m^2}\sum_{j=1}^{m}\sum_{j'=1}^{m} k(y_j, y_{j'}).$$

Para el producto interno cruzado,

$$\begin{aligned}\langle \widehat{\mu}_X, \widehat{\mu}_Y \rangle_{\mathcal{H}_k} &= \left\langle \frac{1}{n}\sum_{i=1}^{n} k(x_i, \cdot), \frac{1}{m}\sum_{j=1}^{m} k(y_j, \cdot) \right\rangle_{\mathcal{H}_k} \\ &= \frac{1}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m} \langle k(x_i, \cdot), k(y_j, \cdot) \rangle_{\mathcal{H}_k} \\ &= \frac{1}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m} k(x_i, y_j).\end{aligned}$$

Sustituyendo estos tres resultados, se obtiene la versión empírica expandida:

$$\boxed{\begin{aligned}\widehat{\mathrm{MMD}}_b^2 = &\frac{1}{n^2}\sum_{i=1}^{n}\sum_{i'=1}^{n} k(x_i, x_{i'}) \\ &+ \frac{1}{m^2}\sum_{j=1}^{m}\sum_{j'=1}^{m} k(y_j, y_{j'}) \\ &- \frac{2}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m} k(x_i, y_j).\end{aligned}}$$

Esta fórmula ya permite calcular la MMD a partir de los datos observados, sin conocer explícitamente las distribuciones $P_X$ y $P_Y$.

**Construcción explícita de las matrices de Gram**

Para escribir la fórmula en forma matricial, se organizan las evaluaciones del kernel en matrices.

La matriz de Gram de la muestra $X$ contiene todas las evaluaciones del kernel entre sus observaciones:

$$\mathbf{K}_{XX} = \begin{bmatrix} k(x_1, x_1) & k(x_1, x_2) & \cdots & k(x_1, x_n) \\ k(x_2, x_1) & k(x_2, x_2) & \cdots & k(x_2, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ k(x_n, x_1) & k(x_n, x_2) & \cdots & k(x_n, x_n) \end{bmatrix} \in \mathbb{R}^{n \times n}.$$

Cada fila corresponde a una observación $x_i$, y cada columna corresponde a una observación $x_{i'}$. La entrada de la fila $i$ y la columna $i'$ es $k(x_i, x_{i'})$.

De forma análoga, la matriz de Gram de la muestra $Y$ es

$$\mathbf{K}_{YY} = \begin{bmatrix} k(y_1, y_1) & k(y_1, y_2) & \cdots & k(y_1, y_m) \\ k(y_2, y_1) & k(y_2, y_2) & \cdots & k(y_2, y_m) \\ \vdots & \vdots & \ddots & \vdots \\ k(y_m, y_1) & k(y_m, y_2) & \cdots & k(y_m, y_m) \end{bmatrix} \in \mathbb{R}^{m \times m}.$$

Por último, la matriz cruzada contiene las evaluaciones del kernel entre las observaciones de las dos muestras:

$$\mathbf{K}_{XY} = \begin{bmatrix} k(x_1, y_1) & k(x_1, y_2) & \cdots & k(x_1, y_m) \\ k(x_2, y_1) & k(x_2, y_2) & \cdots & k(x_2, y_m) \\ \vdots & \vdots & \ddots & \vdots \\ k(x_n, y_1) & k(x_n, y_2) & \cdots & k(x_n, y_m) \end{bmatrix} \in \mathbb{R}^{n \times m}.$$

Las dos primeras matrices son cuadradas porque comparan cada observación de una muestra con todas las observaciones de esa misma muestra. La matriz cruzada tiene $n$ filas y $m$ columnas porque compara cada una de las $n$ observaciones de $X$ con cada una de las $m$ observaciones de $Y$.

Estas matrices se construyen en el espacio original $\mathcal{X}$, evaluando el kernel. No es necesario calcular explícitamente las coordenadas de las observaciones en el espacio de características ni construir directamente las funciones del RKHS.

**De las sumas dobles a los productos matriciales**

El vector de unos no es un elemento adicional de los datos. Es un vector auxiliar que permite sumar todas las entradas de una matriz mediante multiplicación matricial.

Se define

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^{n \times 1}, \qquad \mathbf{1}_n^\mathsf{T} = \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{1 \times n}.$$

El símbolo $^\mathsf{T}$ indica la transpuesta: convierte el vector columna en un vector fila. Se define $\mathbf{1}_m$ de la misma manera, con $m$ entradas iguales a uno.

Consideremos el producto $\mathbf{K}_{XX}\mathbf{1}_n$. Su primera componente es la suma de todos los elementos de la primera fila de $\mathbf{K}_{XX}$; la segunda componente es la suma de la segunda fila, y así sucesivamente:

$$\mathbf{K}_{XX}\mathbf{1}_n = \begin{bmatrix} \sum_{i'=1}^{n} k(x_1, x_{i'}) \\ \sum_{i'=1}^{n} k(x_2, x_{i'}) \\ \vdots \\ \sum_{i'=1}^{n} k(x_n, x_{i'}) \end{bmatrix} \in \mathbb{R}^{n\times 1}.$$

Al multiplicar por la izquierda por $\mathbf{1}_n^\intercal$, se suman todas las componentes de ese vector:

$$\begin{aligned} \mathbf{1}_n^\intercal \mathbf{K}_{XX}\mathbf{1}_n &= \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix} \begin{bmatrix} \sum_{i'=1}^{n} k(x_1, x_{i'}) \\ \sum_{i'=1}^{n} k(x_2, x_{i'}) \\ \vdots \\ \sum_{i'=1}^{n} k(x_n, x_{i'}) \end{bmatrix} \\ &= \sum_{i=1}^{n}\sum_{i'=1}^{n} k(x_i, x_{i'}). \end{aligned}$$

Por tanto,

$$\boxed{\mathbf{1}_n^\intercal \mathbf{K}_{XX}\mathbf{1}_n = \sum_{i=1}^{n}\sum_{i'=1}^{n} k(x_i, x_{i'})}$$

Las dimensiones confirman que la operación es válida:

$$\underbrace{(1\times n)}_{\mathbf{1}_n^\intercal}\underbrace{(n\times n)}_{\mathbf{K}_{XX}}\underbrace{(n\times 1)}_{\mathbf{1}_n} \quad \longrightarrow \quad 1\times 1.$$

El resultado es un escalar que representa la suma de todas las entradas de $\mathbf{K}_{XX}$.
El mismo razonamiento para la muestra $Y$ produce

$$\boxed{\mathbf{1}_m^\intercal \mathbf{K}_{YY}\mathbf{1}_m = \sum_{j=1}^{m}\sum_{j'=1}^{m} k(y_j, y_{j'})}$$

con dimensiones

$$(1\times m)(m\times m)(m\times 1) \longrightarrow 1\times 1.$$

Para la matriz cruzada, la multiplicación por la derecha suma los elementos de cada fila, y la multiplicación por la izquierda suma después los resultados de todas las filas:

$$\boxed{\mathbf{1}_n^\intercal \mathbf{K}_{XY}\mathbf{1}_m = \sum_{i=1}^{n}\sum_{j=1}^{m} k(x_i, y_j)}$$

con dimensiones

$$(1\times n)(n\times m)(m\times 1) \longrightarrow 1\times 1.$$

Así, cada producto matricial representa exactamente una de las sumas dobles de la fórmula empírica. Al sustituirlos, se obtiene la representación matricial solicitada:

$$\boxed{\begin{aligned}\widehat{\mathrm{MMD}}_b^2 = &\frac{1}{n^2}\mathbf{1}_n^\intercal \mathbf{K}_{XX}\mathbf{1}_n \\ &+ \frac{1}{m^2}\mathbf{1}_m^\intercal \mathbf{K}_{YY}\mathbf{1}_m \\ &- \frac{2}{nm}\mathbf{1}_n^\intercal \mathbf{K}_{XY}\mathbf{1}_m.\end{aligned}}$$

Todos los términos de esta expresión son escalares, por lo que se pueden sumar y restar. La forma matricial es una manera compacta de calcular las mismas sumas de evaluaciones del kernel que aparecen en la expresión empírica desarrollada anteriormente.

Para estimar esta cantidad a partir de los datos, se utilizan las observaciones disponibles $x_1, \ldots, x_n$ y $y_1, \ldots, y_m$. En particular, el primer término de la expresión poblacional se aproxima mediante el promedio

$$A_n = \frac{1}{n^2}\sum_{i=1}^{n}\sum_{j=1}^{n} k(x_i, x_j).$$

El denominador $n^2$ aparece porque cada una de las $n$ observaciones se compara con las $n$ observaciones de la muestra, incluida ella misma. Por tanto, se realizan $n \times n = n^2$ comparaciones.

Para ilustrarlo, si $n = 3$, la matriz del kernel es

$$K_{XX} = \begin{pmatrix} k(x_1, x_1) & k(x_1, x_2) & k(x_1, x_3) \\ k(x_2, x_1) & k(x_2, x_2) & k(x_2, x_3) \\ k(x_3, x_1) & k(x_3, x_2) & k(x_3, x_3) \end{pmatrix}.$$

Los elementos de la diagonal, $k(x_1, x_1)$, $k(x_2, x_2)$ y $k(x_3, x_3)$, corresponden a las comparaciones de cada observación consigo misma. En cambio, los elementos fuera de la diagonal corresponden a comparaciones entre observaciones diferentes.

Por ejemplo, para el kernel gaussiano,

$$k(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right),$$

donde $\sigma > 0$ es el parámetro de escala del kernel, se cumple que

$$k(x_i, x_i) = \exp(0) = 1,$$

porque la distancia entre una observación y ella misma es cero. Por su parte, las comparaciones entre observaciones distintas pueden tomar valores entre cero y uno, dependiendo de su distancia.

La inclusión de los términos diagonales no constituye un error matemático. Sin embargo, genera una diferencia entre el promedio empírico y el término poblacional que se desea estimar. En la expresión poblacional, $X$ y $X'$ son observaciones independientes, mientras que en un término diagonal $k(x_i, x_i)$ se utiliza la misma observación dos veces. Por ello, el promedio empírico que incluye la diagonal puede tener un valor esperado diferente del término poblacional.

## 2. Origen del sesgo en el estimador empírico

Para comprender el origen del sesgo, se considera el promedio empírico correspondiente a la muestra $X$:

$$A_n = \frac{1}{n^2} \sum_{i=1}^{n} \sum_{j=1}^{n} k(X_i, X_j).$$

Se supone que $X_1, \ldots, X_n$ son observaciones independientes e idénticamente distribuidas según $P_X$. Al calcular la esperanza de $A_n$, se obtiene:

$$\mathbb{E}[A_n] = \frac{1}{n^2} \sum_{i=1}^{n} \sum_{j=1}^{n} \mathbb{E}[k(X_i, X_j)].$$

Esta igualdad se debe a la linealidad de la esperanza, que permite intercambiar la esperanza y las sumas finitas.

La suma contiene $n^2$ términos, pero estos se dividen en dos grupos. El primero contiene $n(n-1)$ términos fuera de la diagonal, para los cuales $i \neq j$. Como las observaciones son independientes e idénticamente distribuidas, cada uno de estos términos tiene esperanza $\mathbb{E}[k(X, X')]$, donde $X$ y $X'$ son independientes y siguen la distribución $P_X$. El segundo grupo contiene los $n$ términos diagonales, para los cuales $i = j$. Cada uno tiene esperanza $\mathbb{E}[k(X, X)]$.

Por consiguiente,

$$\begin{aligned} \mathbb{E}[A_n] &= \frac{n(n-1)}{n^2} \mathbb{E}[k(X, X')] + \frac{n}{n^2} \mathbb{E}[k(X, X)] \\ &= \frac{n-1}{n} \mathbb{E}[k(X, X')] + \frac{1}{n} \mathbb{E}[k(X, X)]. \end{aligned}$$

Esta expresión muestra que el promedio empírico combina el término poblacional deseado con la contribución de las comparaciones diagonales. En consecuencia, en general,

$$\mathbb{E}[A_n] \neq \mathbb{E}[k(X, X')].$$

La diferencia entre la esperanza del estimador y la cantidad poblacional que se desea estimar se denomina sesgo. Para un estimador $\widehat{\theta}$ de una cantidad poblacional $\theta$, se define como

$$\text{Sesgo}(\widehat{\theta}) = \mathbb{E}[\widehat{\theta}] - \theta.$$

Un estimador es insesgado cuando esta diferencia es cero. En el caso del promedio $A_n$, el sesgo es

$$\text{Sesgo}(A_n) = \frac{1}{n} \left( \mathbb{E}[k(X, X)] - \mathbb{E}[k(X, X')] \right).$$

En particular, con el kernel gaussiano, $k(X, X) = 1$, por lo que

$$\text{Sesgo}(A_n) = \frac{1}{n} \left( 1 - \mathbb{E}[k(X, X')] \right).$$

Esta expresión permite observar que la contribución del sesgo depende del tamaño de la muestra y de la diferencia entre la similitud de una observación consigo misma y la similitud esperada entre dos observaciones independientes.

## 3. El cuadrado de la norma y su relación con el sesgo

El cuadrado presente en la definición de la MMD proviene de la distancia cuadrática entre las medias de características:

$$\mathrm{MMD}^2(P_X, P_Y) = \|\mu_X - \mu_Y\|^2_{\mathcal{H}_k}.$$

La norma mide la magnitud de la diferencia entre las dos medias de características en el espacio $\mathcal{H}_k$. Al elevarla al cuadrado se obtiene una cantidad escalar no negativa que permite expresar la MMD mediante esperanzas de funciones kernel.

Sin embargo, el cuadrado de la norma no elimina el sesgo. Este surge del procedimiento empleado para construir el estimador empírico, en particular de la inclusión de las comparaciones diagonales y de los denominadores utilizados en los promedios. Por tanto, es necesario distinguir entre la definición poblacional de la MMD al cuadrado y el estimador que se calcula a partir de una muestra finita.

## 4. Construcción del estimador insesgado

Para eliminar la contribución de las comparaciones diagonales, se puede modificar el promedio empírico y considerar únicamente los términos para los cuales $i \neq j$. Como se excluyen las $n$ comparaciones diagonales de las $n^2$ comparaciones originales, quedan

$$n^2 - n = n(n-1)$$

términos. En consecuencia, el promedio corregido se define como

$$\boxed{\frac{1}{n(n-1)} \sum_{\substack{i,j=1 \\ i \neq j}}^{n} k(x_i, x_j)}$$

El denominador $n(n-1)$ corresponde al número de comparaciones entre observaciones distintas. Para $n = 3$, por ejemplo, quedan seis términos:

$$\begin{aligned} \frac{1}{6}\Big[&k(x_1, x_2) + k(x_1, x_3) \\ &+ k(x_2, x_1) + k(x_2, x_3) \\ &+ k(x_3, x_1) + k(x_3, x_2)\Big]. \end{aligned}$$

La razón por la que este promedio es insesgado se obtiene calculando su esperanza:

$$\begin{aligned} \mathbb{E}\left[\frac{1}{n(n-1)} \sum_{i \neq j} k(X_i, X_j)\right] &= \frac{1}{n(n-1)} \sum_{i \neq j} \mathbb{E}[k(X_i, X_j)] \\ &= \frac{n(n-1)}{n(n-1)} \mathbb{E}[k(X, X')] \\ &= \mathbb{E}[k(X, X')]. \end{aligned}$$

La segunda igualdad se obtiene porque los $n(n-1)$ términos corresponden a pares de observaciones independientes con la misma distribución conjunta que $(X, X')$. Así,

cada término tiene la misma esperanza y el promedio conserva exactamente la esperanza poblacional deseada.

Para construir el estimador insesgado completo de la MMD al cuadrado, se aplica la misma corrección a la muestra $Y$ y se conserva el término cruzado entre ambas muestras:

$$\widehat{\mathrm{MMD}}_u^2 = \frac{1}{n(n-1)} \sum_{\substack{i,j=1 \\ i \neq j}}^{n} k(x_i, x_j) + \frac{1}{m(m-1)} \sum_{\substack{i,j=1 \\ i \neq j}}^{m} k(y_i, y_j) - \frac{2}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} k(x_i, y_j).$$

En el término cruzado no se excluyen comparaciones diagonales, porque las observaciones $x_i$ y $y_j$ pertenecen a muestras distintas e independientes. Bajo los supuestos de independencia e idéntica distribución dentro de cada muestra, independencia entre ambas muestras y tamaños $n, m \geq 2$, la esperanza de este estimador coincide con la MMD poblacional al cuadrado.

La diferencia fundamental entre los dos estimadores es que el estimador sesgado incluye las comparaciones diagonales y utiliza denominadores $n^2$ y $m^2$, mientras que el estimador insesgado las excluye y utiliza denominadores $n(n-1)$ y $m(m-1)$. El término cruzado mantiene el denominador $nm$ en ambos casos.

## 2.4 Implementación con MNIST y Fashion-MNIST

Listing 2: Enfoques Anteriores en Python

```python
import matplotlib.pyplot as plt
import numpy as np
from scipy.spatial.distance import cdist

try:
    import torchvision
    import torchvision.transforms as transforms

    USAR_TORCH = True
except ImportError:
    from sklearn.datasets import fetch_openml

    USAR_TORCH = False

SEED = 42
np.random.seed(SEED)

if USAR_TORCH:
    tf = transforms.ToTensor()
    ds_m = torchvision.datasets.MNIST(
        root="./data", train=True, download=True, transform=tf
    )
    ds_f = torchvision.datasets.FashionMNIST(
        root="./data", train=True, download=True, transform=tf
    )
```

```
26
27      idx_m = np.random.choice(len(ds_m), 1000, replace=False)
28      idx_f = np.random.choice(len(ds_f), 1000, replace=False)
29
30      X_m = np.array([ds_m[i][0].numpy() for i in idx_m]).reshape(1000,
            784)
31      X_f = np.array([ds_f[i][0].numpy() for i in idx_f]).reshape(1000,
            784)
32  else:
33      data_m, _ = fetch_openml(
34          "mnist_784", version=1, return_X_y=True, as_frame=False, parser=
                "auto"
35      )
36      data_f, _ = fetch_openml(
37          "Fashion-MNIST", version=1, return_X_y=True, as_frame=False,
                parser="auto"
38      )
39
40      idx_m = np.random.choice(len(data_m), 1000, replace=False)
41      idx_f = np.random.choice(len(data_f), 1000, replace=False)
42
43      X_m = data_m[idx_m] / 255.0
44      X_f = data_f[idx_f] / 255.0
45
46  M1, M2 = X_m[:500], X_m[500:]
47  F1, F2 = X_f[:500], X_f[500:]
48
49  muestra_comb = np.vstack([M1, F1])
50  sigma = np.median(cdist(muestra_comb, muestra_comb, metric="euclidean"))
51  print(f"Sigma (mediana): {sigma:.6f}")
52
53
54  def rbf_kernel(X, Y, sigma_val, eps=1e-8):
55      sigma_safe = max(sigma_val, eps)
56      return np.exp(
57          -cdist(X, Y, metric="sqeuclidean") / (2.0 * (sigma_safe**2))
58      )
59
60
61  def calcular_mmd2(X, Y, sigma_val):
62      n, m = X.shape[0], Y.shape[0]
63
64      K_XX = rbf_kernel(X, X, sigma_val)
65      K_YY = rbf_kernel(Y, Y, sigma_val)
66      K_XY = rbf_kernel(X, Y, sigma_val)
67
68      ones_n = np.ones((n, 1))
69      ones_m = np.ones((m, 1))
70
71      term_XX = (ones_n.T @ K_XX @ ones_n) / (n**2)
72      term_YY = (ones_m.T @ K_YY @ ones_m) / (m**2)
73      term_XY = (ones_n.T @ K_XY @ ones_m) / (n * m)
74
75      mmd2 = term_XX + term_YY - 2.0 * term_XY
76      return mmd2[0, 0], K_XX, K_YY, K_XY
77
78
79  mmd2_M1_F1, K_XX, K_YY, K_XY = calcular_mmd2(M1, F1, sigma)
```

```
mmd2_M1_M2, _, _, _ = calcular_mmd2(M1, M2, sigma)
mmd2_F1_F2, _, _, _ = calcular_mmd2(F1, F2, sigma)

print("\n--- RESULTADOS MMD^2 ---")
print(f"MNIST M1 vs Fashion F1  : {mmd2_M1_F1:.6f}")
print(f"MNIST M1 vs MNIST M2    : {mmd2_M1_M2:.6f}")
print(f"Fashion F1 vs Fashion F2: {mmd2_F1_F2:.6f}")

fig, axes = plt.subplots(1, 3, figsize=(12, 3.5))

im0 = axes[0].imshow(K_XX, cmap="viridis")
axes[0].set_title(r"$K_{XX}$ (MNIST vs MNIST)")
plt.colorbar(im0, ax=axes[0])

im1 = axes[1].imshow(K_YY, cmap="viridis")
axes[1].set_title(r"$K_{YY}$ (Fashion vs Fashion)")
plt.colorbar(im1, ax=axes[1])

im2 = axes[2].imshow(K_XY, cmap="viridis")
axes[2].set_title(r"$K_{XY}$ (MNIST vs Fashion)")
plt.colorbar(im2, ax=axes[2])

plt.tight_layout()
plt.show()
```

# 3 Índice de correlación de Pearson: espacio original y RKHS.

## 3.1 Coeficiente de Pearson en el espacio original.

La correlación de Pearson es una medida estadística que cuantifica la intensidad y la dirección de la relación lineal entre dos variables numéricas. Su valor pertenece al intervalo $[-1, 1]$: un valor positivo indica que ambas variables tienden a aumentar o disminuir conjuntamente; un valor negativo indica que tienden a variar en direcciones opuestas; y un valor cercano a cero indica que no se observa una relación lineal marcada. Sin embargo, una correlación nula no implica necesariamente independencia, ya que puede existir una relación no lineal entre las variables.

En aprendizaje automático, la correlación de Pearson se utiliza para estudiar las relaciones lineales entre características (*features*), identificar posibles redundancias entre variables, explorar la relación entre las entradas y la variable objetivo, y analizar la asociación entre predicciones y valores observados. También puede servir como herramienta de análisis preliminar para comprender la estructura de los datos. No obstante, una correlación elevada no implica causalidad y, por sí sola, no permite identificar todas las formas de dependencia entre variables.

Sean $X$ e $Y$ dos variables aleatorias con medias finitas y varianzas positivas. La correlación poblacional de Pearson se define como

$$\rho_{XY} = \frac{\operatorname{Cov}(X, Y)}{\sqrt{\operatorname{Var}(X)\operatorname{Var}(Y)}},$$

donde $\operatorname{Cov}(X, Y)$ es la covarianza entre las variables y $\operatorname{Var}(X)$, $\operatorname{Var}(Y)$ son sus respec-

tivas varianzas. La covarianza mide cómo varían conjuntamente las dos variables, mientras que la división por el producto de sus desviaciones estándar normaliza esa medida y permite obtener un coeficiente adimensional.

Si se dispone de $n$ observaciones emparejadas, representadas por $(x_i, y_i)$, con $i = 1, \ldots, n$, la correlación muestral de Pearson se calcula mediante

$$r_{XY} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}},$$

donde las medias muestrales son

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad \bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i.$$

La expresión resta las medias a las observaciones antes de medir su relación. Este procedimiento, denominado centrado, es necesario porque la correlación describe la variación conjunta de las variables respecto de sus medias, no respecto del origen arbitrario de sus escalas.

**Representación matricial del centrado**

Para expresar estas operaciones mediante álgebra lineal, se organizan las observaciones en vectores columna:

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^{n\times 1}, \qquad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^{n\times 1}.$$

Cada vector contiene las observaciones de una variable, y las posiciones correspondientes de ambos vectores representan observaciones emparejadas. Se define, además, el vector de unos

$$\mathbf{1}_n = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \in \mathbb{R}^{n\times 1},$$

que permite expresar las medias y el centrado de forma compacta.

La media muestral de $X$ puede escribirse como

$$\boxed{\bar{x} = \frac{1}{n}\mathbf{1}_n^\top \mathbf{x}}$$

Para comprender cómo esta multiplicación matricial equivale a sumar todas las observaciones, se escriben explícitamente los dos vectores que intervienen:

$$\mathbf{1}_n^\top = \begin{pmatrix} 1 & 1 & \cdots & 1 \end{pmatrix} \in \mathbb{R}^{1\times n},$$

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^{n\times 1}.$$

Al multiplicar el vector fila por el vector columna, cada elemento del vector fila multiplica la entrada que ocupa la misma posición en el vector columna. Luego se suman los productos obtenidos:

$$\begin{aligned} \mathbf{1}_n^\top \mathbf{x} &= \begin{pmatrix} 1 & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \\ &= 1x_1 + 1x_2 + \cdots + 1x_n \\ &= \sum_{i=1}^{n} x_i. \end{aligned}$$

Por tanto, al multiplicar este resultado por $1/n$, se obtiene exactamente la media aritmética:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Las dimensiones explican por qué el resultado es un escalar:

$$\underbrace{\mathbf{1}_n^\top}_{1\times n} \underbrace{\mathbf{x}}_{n\times 1} \quad \longrightarrow \quad \underbrace{\mathbf{1}_n^\top \mathbf{x}}_{1\times 1}.$$

El número de columnas del primer factor coincide con el número de filas del segundo, por lo que la multiplicación está definida. El resultado tiene una fila y una columna. La media de $Y$ se obtiene de la misma manera:

$$\boxed{\bar{y} = \frac{1}{n} \mathbf{1}_n^\top \mathbf{y} = \frac{1}{n} \sum_{i=1}^{n} y_i}$$

Los vectores centrados se definen restando la media correspondiente a cada observación:

$$\mathbf{x}_c = \mathbf{x} - \bar{x}\mathbf{1}_n, \qquad \mathbf{y}_c = \mathbf{y} - \bar{y}\mathbf{1}_n.$$

Aquí, $\bar{x}$ y $\bar{y}$ son escalares. Para que la resta sea válida, cada media se multiplica por el vector de unos, de modo que el escalar se replica en las $n$ posiciones. Así,

$$\bar{x}\mathbf{1}_n = \begin{pmatrix} \bar{x} \\ \bar{x} \\ \vdots \\ \bar{x} \end{pmatrix} \in \mathbb{R}^{n\times 1}.$$

Por consiguiente, la operación de centrado también se puede escribir componente a componente:

$$\mathbf{x}_c = \begin{pmatrix} x_1 - \bar{x} \\ x_2 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{pmatrix} \in \mathbb{R}^{n\times 1}.$$

De manera análoga,

$$\mathbf{y}_c = \begin{pmatrix} y_1 - \bar{y} \\ y_2 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{pmatrix} \in \mathbb{R}^{n\times 1}.$$

El centrado consiste, por tanto, en restar la media de la variable a cada una de sus observaciones.

**La matriz de centrado**

El centrado también puede representarse mediante una única matriz. Para obtenerla, se sustituye la expresión matricial de la media en la definición del vector centrado:

$$\begin{aligned} \mathbf{x}_c &= \mathbf{x} - \bar{x}\mathbf{1}_n \\ &= \mathbf{x} - \frac{1}{n}(\mathbf{1}_n^\top \mathbf{x})\mathbf{1}_n. \end{aligned}$$

El término $\mathbf{1}_n^\top \mathbf{x}$ es un escalar, de modo que se puede reorganizar la multiplicación sin alterar el resultado:

$$\mathbf{x}_c = \mathbf{x} - \frac{1}{n}\mathbf{1}_n(\mathbf{1}_n^\top \mathbf{x}).$$

Por la propiedad asociativa de la multiplicación matricial,

$$\mathbf{x}_c = \mathbf{x} - \frac{1}{n}(\mathbf{1}_n\mathbf{1}_n^\top)\mathbf{x}.$$

En esta expresión, $\mathbf{1}_n\mathbf{1}_n^\top$ es una matriz de dimensiones $n \times n$. Al agrupar los términos que multiplican a $\mathbf{x}$, resulta

$$\mathbf{x}_c = \left(I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top\right)\mathbf{x},$$

donde $I_n \in \mathbb{R}^{n\times n}$ es la matriz identidad. Esto motiva la definición de la matriz de centrado:

$$\boxed{H = I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top}$$

Tanto $I_n$ como $\mathbf{1}_n\mathbf{1}_n^\top$ tienen dimensiones $n \times n$, por lo que su resta está definida y $H \in \mathbb{R}^{n\times n}$.

La estructura de esta matriz se obtiene al multiplicar explícitamente el vector de unos por su transpuesta:

$$\mathbf{1}_n\mathbf{1}_n^\top = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & \cdots & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{pmatrix}.$$

Al multiplicar $H$ por el vector de observaciones, la operación puede verse directamente:

$$\begin{aligned} H\mathbf{x} &= \left(I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top\right)\mathbf{x} \\ &= \mathbf{x} - \frac{1}{n}\mathbf{1}_n\left(\mathbf{1}_n^\top\mathbf{x}\right) \\ &= \mathbf{x} - \frac{1}{n}\mathbf{1}_n\sum_{i=1}^{n} x_i \\ &= \mathbf{x} - \bar{x}\mathbf{1}_n \\ &= \mathbf{x}_c. \end{aligned}$$

La multiplicación por $H$ produce así el vector de observaciones centradas. De igual manera,

$$\boxed{\mathbf{x}_c = H\mathbf{x}, \qquad \mathbf{y}_c = H\mathbf{y}.}$$

Una propiedad fundamental de $H$ es que sus filas y columnas suman cero, lo que se expresa mediante

$$H\mathbf{1}_n = \mathbf{0},$$

donde $\mathbf{0} \in \mathbb{R}^{n\times 1}$ es el vector nulo. En efecto,

$$\begin{aligned} H\mathbf{1}_n &= \left(I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top\right)\mathbf{1}_n \\ &= \mathbf{1}_n - \frac{1}{n}\mathbf{1}_n(\mathbf{1}_n^\top\mathbf{1}_n). \end{aligned}$$

Como $\mathbf{1}_n^\top\mathbf{1}_n = n$, se sigue que

$$H\mathbf{1}_n = \mathbf{1}_n - \frac{1}{n}\mathbf{1}_n n = \mathbf{0}.$$

Esta propiedad garantiza que los vectores centrados tienen media cero. Para comprobarlo en $\mathbf{x}_c$, se calcula

$$\begin{aligned} \frac{1}{n}\mathbf{1}_n^\top\mathbf{x}_c &= \frac{1}{n}\mathbf{1}_n^\top H\mathbf{x} \\ &= 0, \end{aligned}$$

donde se ha utilizado que $H$ es simétrica y que $H\mathbf{1}_n = \mathbf{0}$.

Además, $H$ es simétrica, es decir, $H^\top = H$, e idempotente, lo que significa que $H^2 = H$. La simetría se obtiene de su definición, ya que tanto la identidad como $\mathbf{1}_n\mathbf{1}_n^\top$ son matrices simétricas. Para la idempotencia, se parte de

$$H^2 = \left(I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top\right)\left(I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top\right).$$

Al desarrollar el producto,

$$H^2 = I_n - \frac{2}{n}\mathbf{1}_n\mathbf{1}_n^\top + \frac{1}{n^2}\mathbf{1}_n\mathbf{1}_n^\top\mathbf{1}_n\mathbf{1}_n^\top.$$

Como $\mathbf{1}_n^\top\mathbf{1}_n = n$, el último término se simplifica a

$$\frac{1}{n^2}\mathbf{1}_n(\mathbf{1}_n^\top\mathbf{1}_n)\mathbf{1}_n^\top = \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top.$$

Por tanto,

$$\begin{aligned} H^2 &= I_n - \frac{2}{n}\mathbf{1}_n\mathbf{1}_n^\top + \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top \\ &= I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top \\ &= H. \end{aligned}$$

La idempotencia expresa que centrar dos veces produce el mismo resultado que centrar una sola vez.

**Correlación de Pearson en forma matricial**

Una vez definidos los vectores centrados, el numerador de la correlación muestral puede escribirse como un producto interno:

$$\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = \mathbf{x}_c^\top\mathbf{y}_c.$$

Para ver cómo aparece la suma, se escribe el producto de forma explícita:

$$\mathbf{x}_c^\top\mathbf{y}_c = \begin{pmatrix} x_1 - \bar{x} & x_2 - \bar{x} & \cdots & x_n - \bar{x} \end{pmatrix} \begin{pmatrix} y_1 - \bar{y} \\ y_2 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{pmatrix}$$

$$\begin{aligned} &= (x_1 - \bar{x})(y_1 - \bar{y}) \\ &\quad + (x_2 - \bar{x})(y_2 - \bar{y}) \\ &\quad + \cdots \\ &\quad + (x_n - \bar{x})(y_n - \bar{y}) \\ &= \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}). \end{aligned}$$

Las dimensiones de esta operación son

$$\underbrace{\mathbf{x}_c^\top}_{1\times n}\underbrace{\mathbf{y}_c}_{n\times 1} \longrightarrow \underbrace{\mathbf{x}_c^\top\mathbf{y}_c}_{1\times 1}.$$

El resultado es un escalar que suma los productos de las observaciones centradas correspondientes.

De forma análoga, las sumas de cuadrados del denominador se expresan como

$$\sum_{i=1}^{n}(x_i - \bar{x})^2 = \mathbf{x}_c^\top\mathbf{x}_c$$

y

$$\sum_{i=1}^{n}(y_i - \bar{y})^2 = \mathbf{y}_c^\top\mathbf{y}_c.$$

Por ejemplo, el primer producto se desarrolla como

$$\mathbf{x}_c^\top \mathbf{x}_c = \begin{pmatrix} x_1 - \bar{x} & \cdots & x_n - \bar{x} \end{pmatrix} \begin{pmatrix} x_1 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{pmatrix}$$
$$= \sum_{i=1}^{n} (x_i - \bar{x})^2.$$

Al sustituir estas identidades en la definición de la correlación muestral, resulta

$$\boxed{r_{XY} = \frac{\mathbf{x}_c^\top \mathbf{y}_c}{\sqrt{(\mathbf{x}_c^\top \mathbf{x}_c)(\mathbf{y}_c^\top \mathbf{y}_c)}}}$$

Esta expresión requiere que ambos vectores centrados tengan norma distinta de cero; de lo contrario, alguna de las variables es constante en la muestra y la correlación no está definida.

Finalmente, al sustituir $\mathbf{x}_c = H\mathbf{x}$ y $\mathbf{y}_c = H\mathbf{y}$, se obtiene

$$r_{XY} = \frac{(H\mathbf{x})^\top (H\mathbf{y})}{\sqrt{\left[(H\mathbf{x})^\top (H\mathbf{x})\right]\left[(H\mathbf{y})^\top (H\mathbf{y})\right]}}.$$

Como $H^\top = H$ e $H^2 = H$, el numerador puede simplificarse de la siguiente manera:

$$\begin{aligned} (H\mathbf{x})^\top (H\mathbf{y}) &= \mathbf{x}^\top H^\top H\mathbf{y} \\ &= \mathbf{x}^\top H^2 \mathbf{y} \\ &= \mathbf{x}^\top H\mathbf{y}. \end{aligned}$$

Aplicando las mismas propiedades a los términos del denominador,

$$(H\mathbf{x})^\top (H\mathbf{x}) = \mathbf{x}^\top H\mathbf{x},$$

$$(H\mathbf{y})^\top (H\mathbf{y}) = \mathbf{y}^\top H\mathbf{y}.$$

Por tanto, la correlación de Pearson admite la representación matricial equivalente

$$\boxed{r_{XY} = \frac{\mathbf{x}^\top H\mathbf{y}}{\sqrt{(\mathbf{x}^\top H\mathbf{x})(\mathbf{y}^\top H\mathbf{y})}}}$$

Esta forma muestra que la correlación se obtiene a partir de productos matriciales que incorporan el centrado de las observaciones. Geométricamente, $r_{XY}$ coincide con el coseno del ángulo entre los vectores centrados:

$$r_{XY} = \frac{\mathbf{x}_c^\top \mathbf{y}_c}{\|\mathbf{x}_c\|_2 \|\mathbf{y}_c\|_2},$$

donde $\|\cdot\|_2$ denota la norma euclídea. Esta interpretación permite entender por qué el signo de la correlación depende de la orientación relativa de los vectores centrados: si apuntan en direcciones similares, la correlación es positiva; si apuntan en direcciones opuestas, es negativa; y si son ortogonales, su producto interno es cero.